

AULA 01

CIÊNCIA DE DADOS


PROFESSORA: CAMILA ALVES

Contexto Histórico



“the sexiest job in the next 10 years will be statisticians.” – Varian, Hal (2009). Economista-chefe do Google de 2002 até o presente.

Contexto Histórico



“Statistics is now the sexiest job around” – Rosling, Hans. Documentário da BBC em 2011.

Contexto Histórico



Outubro de 2012

Thomas H. Davenport e D.J. Patil

Data Scientist: The Sexiest Job of the 21st Century

“Cientistas de Dados hoje são como os quants de Wall Street nas décadas de 80 e 90.”

Características de um Data Scientist

MATH & STATISTICS

- ☆ Machine learning
- ☆ Statistical modeling
- ☆ Experiment design
- ☆ Bayesian inference
- ☆ Supervised learning: decision trees, random forests, logistic regression
- ☆ Unsupervised learning: clustering, dimensionality reduction
- ☆ Optimization: gradient descent and variants

DOMAIN KNOWLEDGE & SOFT SKILLS

- ☆ Passionate about the business
- ☆ Curious about data
- ☆ Influence without authority
- ☆ Hacker mindset
- ☆ Problem solver
- ☆ Strategic, proactive, creative, innovative and collaborative




PROGRAMMING & DATABASE

- ☆ Computer science fundamentals
- ☆ Scripting language e.g. Python
- ☆ Statistical computing package e.g. R
- ☆ Databases SQL and NoSQL
- ☆ Relational algebra
- ☆ Parallel databases and parallel query processing
- ☆ MapReduce concepts
- ☆ Hadoop and Hive/Pig
- ☆ Custom reducers
- ☆ Experience with xaaS like AWS

COMMUNICATION & VISUALIZATION

- ☆ Able to engage with senior management
- ☆ Story telling skills
- ☆ Translate data-driven insights into decisions and actions
- ☆ Visual art design
- ☆ R packages like ggplot or lattice
- ☆ Knowledge of any of visualization tools e.g. Flare, D3.js, Tableau

Características de um Data Scientist



Exemplos de Ferramentas de um Data Scientist

Extração de Dados e Manipulação de Dados



presto

R Studio




Selenium



Visualização de Dados



Modelagem



Comunicação



Conceito

Ciência de Dados

É o **processo** de **exploração, manipulação e análise** dos dados para a **descoberta e previsão** através da criação de **hipóteses, testes e validação** com o objetivo de **responder perguntas do negócio e / ou fazer recomendações** capazes de serem diferenciais de negócio.

Todo esse processo precisa ter um forte **embasamento estatístico e matemático** e ser **diretamente ligado ao negócio**, além de poder ser feito de forma **escalável e replicável**.

Processo Científico

Não adianta um processo que demora 5 horas para rodar se você precisa de respostas imediatas

Conceito

Existe um método científico!
Observação, hipóteses, testes e
validação, análises,
monitoramento.

Ciência de Dados



Precisamos que existam dados armazenados
(ou pelo menos começar esse armazenamento).
Armazenamento, processamento, visualização.

Ciência de Dados x Inteligência Artificial

1. Ciência de Dados:

- **Objetivo:** A ciência de dados concentra-se na extração de informações significativas a partir de dados brutos. Visa compreender padrões, tendências e insights por meio de análise estatística e técnica.
- **Processo:** Envolve a coleta, limpeza, transformação e análise de dados para tomar decisões informadas e resolver problemas complexos.
- **Ferramentas e Técnicas:** Utiliza estatísticas, aprendizado de máquina, visualização de dados e outras técnicas para extrair conhecimento dos dados.


2. Inteligência Artificial (IA):

- **Objetivo:** A IA visa criar sistemas que podem realizar tarefas que normalmente requerem inteligência humana. Essas tarefas podem incluir reconhecimento de padrões, tomada de decisões, aprendizado e resolução de problemas.
- **Abordagens:** Pode ser dividida em várias abordagens, como aprendizado de máquina (um subconjunto da IA), redes neurais, processamento de linguagem natural, visão computacional, entre outras.
- **Aplicações:** A IA é usada em uma variedade de campos, desde reconhecimento de voz em assistentes virtuais até diagnóstico médico, condução autônoma, previsões de mercado e muito mais.

Ciência de Dados x Inteligência Artificial

- A ciência de dados é frequentemente uma parte fundamental do desenvolvimento de sistemas de inteligência artificial. Os cientistas de dados podem usar técnicas de análise de dados para extrair informações que alimentam os modelos de IA.
- O aprendizado de máquina, uma subárea da IA, é comumente usado na ciência de dados para construir modelos preditivos e analíticos.

Machine Learning (Aprendizado de Máquina) é um subcampo da inteligência artificial (IA) que se concentra no desenvolvimento de algoritmos e modelos que permitem a um sistema aprender padrões a partir de dados. Em vez de programar explicitamente regras para executar uma tarefa, o sistema é treinado usando dados para reconhecer padrões e tomar decisões com base nesses padrões.



O QUE EU
QUERO



RESPONDER?

O QUE EU
QUERO



RESPONDER?



Qual a resposta da vida, do
universo e tudo mais?

O QUE EU
QUERO



RESPONDER?




Qual a resposta da vida, do
universo e tudo mais?




42

Tecnologia x Negócios x Matemática




Tecnologia x Negócios x Matemática





Ciência de dados não é apenas Machine Learning!

É aplicar o ML de acordo com as necessidades do negócio



**Considerar apenas
Matemática x
Negócio**

**O tamanho da base pode
tornar a análise inviável**



Considerar apenas Tecnologia x Negócio



Conclusões que estão corretas mas
estatisticamente tem pouca validade
Softwares tradicionais (excel, SAS, etc)



Cidade	Temp Média
Cidade 1	30,5
Cidade 2	31,3

Qual cidade é o melhor
destino?????




Considerar apenas Tecnologia x Negócio

Como a temperatura
está distribuída? Existe
desvio de dados?



Conclusões que estão corretas mas
estatisticamente tem pouca validade
Softwares tradicionais (excel, SAS, etc)

Cidade	Temp Média
Cidade 1	30,5
Cidade 2	31,3



**Considerar apenas
Tecnologia x
Matemática**


**Decisões que não fazem
sentido para o negócio**

Formas de fazer publicidade

Canal	Retorno do Investimento
TV	0,8
Jornal	1,1
Blogs / Sites	2,7
Orkut	5,3

**A empresa deve usar o Orkut como principal
investimento para ações de marketing em 2022**

Exemplos




Instagram: feed, reels, explorar,...
"ah, o algoritmo do Instagram..."



**Netflix: indicação de
filmes / séries**



Exemplos




Carros autônomos



CRISP-DM (Cross Industry Standard Process for Data Mining)



CRISP-DM (Cross Industry Standard Process for Data Mining)



CRISP-DM (Cross Industry Standard Process for Data Mining)



Entendimento dos dados




Engenharia de dados




Preparação dos dados

CRISP-DM (Cross Industry Standard Process for Data Mining)



CRISP-DM (Cross Industry Standard Process for Data Mining)




CRISP-DM (Cross Industry Standard Process for Data Mining)

fraud_dataset												
Gender	Married	Dependents	Education	Self_Employed	ApplicantIncome	CoapplicantIncome	LoanAmount	Loan_Term	Credit_History_Available	Housing	Locality	Fraud_Risk
1	0	0	1	0	5849	0	146	360	1	1	1	0
1	1	1	1	1	4583	1508	128	360	1	1	3	1
1	1	0	1	1	3000	0	66	360	1	1	1	1
1	1	0	0	1	2583	2358	120	360	1	1	1	1
1	0	0	1	0	6000	0	141	360	1	1	1	0
1	1	2	1	1	5417	4196	267	360	1	0	1	1
1	1	0	0	1	2333	1516	95	360	1	1	1	1
1	1	3	1	1	3036	2504	158	360	0	1	2	1
1	1	2	1	1	4006	1526	168	360	1	1	1	1
1	1	1	1	1	12841	10968	349	360	1	0	2	1
1	1	2	1	1	3200	700	70	360	1	0	1	1
1	1	2	1	1	2500	1840	109	360	1	0	1	1
1	1	2	1	1	3073	8106	200	360	1	0	1	1
1	0	0	1	0	1853	2840	114	360	1	1	3	1
1	1	2	1	1	1299	1086	17	120	1	1	1	1
1	0	0	1	0	4950	0	125	360	1	1	1	0
1	0	1	0	0	3596	0	100	240	1	1	1	0
0	0	0	1	0	3510	0	76	360	0	1	1	1
1	1	0	0	1	4887	0	133	360	1	1	3	1
1	1	0	1	1	2600	3500	115	12	1	1	1	1
1	1	0	0	1	7660	0	104	360	0	1	1	1
1	1	1	1	1	5955	5625	315	360	1	0	1	1
1	1	0	0	1	2600	1911	116	360	0	1	2	1
0	1	2	0	1	3365	1917	112	360	0	0	3	1
1	1	1	1	1	3717	2925	151	360	1	0	2	1

kaggle


<https://www.kaggle.com/code/labhishekl/fraud-transaction-detection/notebook>

CRISP-DM (Cross Industry Standard Process for Data Mining)



CRISP-DM (Cross Industry Standard Process for Data Mining)

Implementação



CRISP-DM (Cross Industry Standard Process for Data Mining)



Fluxo Completo



Exemplo Prático



Exemplo Prático



Exemplo Prático



AUMENTAR
O ESTOQUE



Exemplo Prático




AUMENTAR
O ESTOQUE



Exemplo Prático



AUMENTAR
O ESTOQUE



Exemplo Prático



ENTENDIMENTO DO
PROBLEMA DE
NEGÓCIO



EXISTÊNCIA DE
DADOS
HISTÓRICOS



ente




HIPÓTESE: esse item
vai aumentar as
vendas no próximo
furacão?

VALIDAÇÃO: aumento
real da venda em 7x



IBM Auto AI



Pipeline leaderboard

Rank	↑	Name	Algorithm	Accuracy (Optimized)	Enhancements	Build time
>	★ 1	Pipeline 4	Gradient Boosting Classifier	0.807	HPO-1 FE HPO-2	00:00:50
>	2	Pipeline 3	Gradient Boosting Classifier	0.804	HPO-1 FE	00:02:32

Notebook

Fraud Transaction Detecti...

Draft saved

FileEditViewRunAdd-onsHelp

+

✂

📄

📋

▶

▶▶

Run All

Markdown ▾

●

Draft Session off (run a cell to start)

🔌

🔄

⋮

+ Code

+ Markdown

[]:

```
import pandas as pd
import numpy as np
```

⏏

Expand

[]:

```
import warnings
warnings.filterwarnings("ignore", category=DeprecationWarning)
```

⏏

Expand

[]:

```
import seaborn as sns
import matplotlib.pyplot as plt
```

⏏

Expand

[]:

```
data = pd.read_csv('../input/PS_20174392719_1491204439457_log.csv')
```

⏏

Notebook

Data Cleaning

```
import pandas as pd
import numpy as np
import pickle
```

Expand

```
import warnings
warnings.filterwarnings("ignore", category=DeprecationWarning)
```

Expand

```
data_fraud = pd.read_csv('../input/PS_20174392719_1491204439457_log.csv')
```

Expand

```
data_fraud = data_fraud.replace(to_replace={'PAYMENT':1, 'TRANSFER':2, 'CASH_OUT':3,
                                             'CASH_IN':4, 'DEBIT':5, 'No':0, 'Yes':1})
```

Expand

```
data_fraud.drop(['nameOrig', 'nameDest', 'isFlaggedFraud'], axis=1, inplace=True)
```

Expand


```
data_fraud.head()
```

Expand

```
X = data_fraud.drop(['isFraud'], axis=1)
y = data_fraud[['isFraud']]
```

Notebook

```
:  
var = data.groupby('type').amount.sum()  
fig = plt.figure()  
ax1 = fig.add_subplot(1,1,1)  
var.plot(kind='bar')  
ax1.set_title("Total amount per transaction type")  
ax1.set_xlabel('Type of Transaction')  
ax1.set_ylabel('Amount');
```



Notebook

Machine Learning Model

```
from sklearn.model_selection import train_test_split
train_X, test_X, train_y, test_y = train_test_split(X, y, test_size = 0.2, random_state = 121)
```

Expand

```
from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier(n_estimators=15)
```

Expand

```
if True:
    probabilities = clf.fit(train_X, train_y.values.ravel()).predict(test_X)
```

Expand

Aprendizado Supervisionado x Aprendizado Não Supervisionado

Aprendizado Supervisionado:

- 1. **Regressão Linear:** Utilizado para problemas de regressão, onde a saída é uma variável contínua.
- 2. **Regressão Logística:** Usado para problemas de classificação binária, prevendo a probabilidade de uma instância pertencer a uma classe.
- 3. **Máquinas de Vetores de Suporte (SVM):** Útil para classificação e regressão, trabalha encontrando o hiperplano que melhor separa as classes.
- 4. **Árvores de Decisão:** Modelos que representam decisões em uma estrutura de árvore. Podem ser usadas para classificação e regressão.
- 5. **Random Forest:** Um ensemble de várias árvores de decisão, usado para melhorar o desempenho e reduzir o overfitting.
- 6. **K-Nearest Neighbors (KNN):** Classificação ou regressão baseada na proximidade das instâncias de treinamento.

Aprendizado Não Supervisionado:

1. **K-Means:** Algoritmo de agrupamento que divide os dados em clusters, onde cada instância pertence ao cluster com o centroide mais próximo.
2. **Análise de Componentes Principais (PCA):** Utilizado para redução de dimensionalidade, transformando dados em um espaço de características de menor dimensão.
3. **Algoritmos de Associação (Apriori, Eclat):** Usados para encontrar padrões e associações em conjuntos de dados.
4. **Mapas Auto-Organizáveis (SOM):** Algoritmo de aprendizado não supervisionado que mapeia instâncias de entrada em uma grade bidimensional.

Métricas

Acurácia (Accuracy):

- **Definição:** Proporção de predições corretas em relação ao total de predições.
- **Fórmula:**
$$\text{Acurácia} = \frac{\text{Número de predições corretas}}{\text{Total de predições}}$$
- **Uso:** Útil quando as classes do conjunto de dados estão balanceadas.

Precisão (Precision):

- **Definição:** Mede a precisão das previsões positivas em relação ao total de previsões positivas.
- **Fórmula:**
$$\text{Precisão} = \frac{\text{Verdadeiros Positivos}}{\text{Verdadeiros Positivos} + \text{Falsos Positivos}}$$
- **Uso:** Importante quando o custo de falsos positivos é alto.

Recall (Sensibilidade ou Revocação):

- **Definição:** Mede a capacidade do modelo de capturar todos os exemplos positivos.
- **Fórmula:**
$$\text{Recall} = \frac{\text{Verdadeiros Positivos}}{\text{Verdadeiros Positivos} + \text{Falsos Negativos}}$$
- **Uso:** Importante quando o custo de falsos negativos é alto.

F1-Score:

- **Definição:** Média harmônica entre precisão e recall.
- **Fórmula:**
$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$
- **Uso:** Útil quando há um equilíbrio entre precisão e recall.

Matriz de Confusão:

- **Definição:** Tabela que mostra a contagem de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.
- **Uso:** Ajuda a visualizar o desempenho do modelo para diferentes classes.

Área Sob a Curva ROC (AUC-ROC):

- **Definição:** Mede a capacidade do modelo de distinguir entre classes positivas e negativas.
- **Uso:** Útil para problemas de classificação binária.

Log Loss (Entropia Cruzada Logarítmica):

- **Definição:** Mede a performance de um modelo de probabilidade.
- **Uso:** Comum em problemas de classificação com saídas probabilísticas.

OBRIGADA!!