

AULA 03

APRENDIZADO SUPERVISIONADO - PARTE 1

PROFESSORA: CAMILA ALVES

APRENDIZADO DE MÁQUINA: ABORDAGEM ORIENTADA A DADOS

INTRODUÇÃO

Que cara têm os nossos dados?

- **Dados Não-estruturados:** armazenado em formato nativo, sem estrutura pré-definida, mais difícil de analisar e processar



- **Dados Estruturados:** tabulares, campos pré-definidos, organizado utilizando estrutura relacional, fácil de analisar e processar

	Sepal Length	Sepal Width	Petal Length	Petal Width	Species
#1	5.1	3.5	1.4	0.2	Iris Setosa
#2	7.0	3.2	4.7	1.4	Iris Versicolor
#3	6.3	3.3	6.0	2.5	Iris Virginica

INTRODUÇÃO

Dados: conceitos básicos

- Representado através de uma matriz com **N** linhas e **D** colunas



The diagram illustrates a data matrix with 3 rows and 4 columns. A vertical double-headed arrow on the left is labeled 'N', representing the number of rows. A horizontal double-headed arrow at the bottom is labeled 'D', representing the number of columns. The matrix contains the following data:

	Sepal Length	Sepal Width	Petal Length	Petal Width
#1	5.1	3.5	1.4	0.2
#2	7.0	3.2	4.7	1.4
#3	6.3	3.3	6.0	2.5

INTRODUÇÃO

Dados: conceitos básicos

- Representado através de uma matriz com **N** linhas e **D** colunas
- **Instância:** unidade observacional que compõe o conjunto de dados



The diagram illustrates a data matrix with dimensions **N** (rows) and **D** (columns). The matrix is represented as a table with 3 rows and 4 columns. The first column contains instance identifiers (#1, #2, #3). The subsequent columns are labeled 'Sepal Length', 'Sepal Width', 'Petal Length', and 'Petal Width'. The first row is highlighted with a green border. A vertical double-headed arrow on the left indicates the number of rows (**N**), and a horizontal double-headed arrow at the bottom indicates the number of columns (**D**).

	Sepal Length	Sepal Width	Petal Length	Petal Width
#1	5.1	3.5	1.4	0.2
#2	7.0	3.2	4.7	1.4
#3	6.3	3.3	6.0	2.5

INTRODUÇÃO

Dados: conceitos básicos

- Representado através de uma matriz com **N** linhas e **D** colunas
- **Instância:** unidade observacional que compõe o conjunto de dados
- **Atributo:** característica ou aspecto mensurável a respeito das instâncias



	Sepal Length	Sepal Width	Petal Length	Petal Width
#1	5.1	3.5	1.4	0.2
#2	7.0	3.2	4.7	1.4
#3	6.3	3.3	6.0	2.5

INTRODUÇÃO

Dados: conceitos básicos

- Representado através de uma matriz com **N** linhas e **D** colunas
- **Instância:** unidade observacional que compõe o conjunto de dados
- **Atributo:** característica ou aspecto mensurável a respeito das instâncias
 - Cada instância é descrita por um **vetor de atributos**

	Sepal Length	Sepal Width	Petal Length	Petal Width
#1	5.1	3.5	1.4	0.2
#2	7.0	3.2	4.7	1.4
#3	6.3	3.3	6.0	2.5

INTRODUÇÃO

Dados: conceitos básicos

- Representado através de uma matriz com **N** linhas e **D** colunas
- **Instância:** unidade observacional que compõe o conjunto de dados
- **Atributo:** característica ou aspecto mensurável a respeito das instâncias
 - Cada instância é descrita por um **vetor de atributos**
- **Atributo Alvo:** fenômeno de interesse sobre o qual deseja-se fazer previsões
 - Em aprendizado supervisionado, representa a saída esperada (y)

	Sepal Length	Sepal Width	Petal Length	Petal Width	Species
#1	5.1	3.5	1.4	0.2	Iris Setosa
#2	7.0	3.2	4.7	1.4	Iris Versicolor
#3	6.3	3.3	6.0	2.5	Iris Virginica

INTRODUÇÃO

Dados: conceitos básicos

- Representado através de uma matriz com **N** linhas e **D** colunas
- **Instância:** unidade observacional que compõe o conjunto de dados
- **Atributo:** característica ou aspecto mensurável a respeito das instâncias
 - Cada instância é descrita por um **vetor de atributos**
- **Atributo Alvo:** fenômeno de interesse sobre o qual deseja-se fazer previsões
 - Em aprendizado supervisionado, representa a saída esperada (y)
 - Cada instância é representada por um par de vetor de atributos e saída $\{\mathbf{x}, y\}$







	Sepal Length	Sepal Width	Petal Length	Petal Width	Species
#1	5.1	3.5	1.4	0.2	Iris Setosa
#2	7.0	3.2	4.7	1.4	Iris Versicolor
#3	6.3	3.3	6.0	2.5	Iris Virginica

INTRODUÇÃO

Dados: conceitos básicos

- Muitos algoritmos de AM são **sensíveis** ao intervalo de valores dos atributos (especialmente se há variabilidade entre os atributos)
 - Visualização: entender o comportamento dos dados
 - Pré-processamento: adaptar valores para intervalos apropriados



INTRODUÇÃO

O que é **Aprendizado** de Máquina?

- Definição clássica: Mitchell (1997)

“Um programa de computador é dito **aprender** a partir de uma experiência **E** com respeito a alguma classe de tarefas **T** e medida de desempenho **P**, se seu desempenho em tarefas de **T**, medido por **P**, melhora com a experiência **E**.”

INTRODUÇÃO

O que é **Aprendizado** de Máquina?

- Definição clássica: Mitchell (1997)

“Um programa de computador é dito **aprender** a partir de uma experiência **E** com respeito a alguma classe de tarefas **T** e medida de desempenho **P**, se seu desempenho em tarefas de **T**, medido por **P**, melhora com a experiência **E**.”

Exemplo: jogar xadrez


- **T:** jogar xadrez
- **P:** percentual de jogos vencidos
- **E:** praticar jogando contra si próprio ou contra adversários (humanos ou não)



INTRODUÇÃO


Em AM, o conjunto de dados representa a **experiência** passada. Utilizamos um **algoritmo de aprendizado** para realizar a **indução de hipóteses** a partir dos dados

- Descoberta de regularidades implícitas aos dados (**padrões**)
- Uma **hipótese** representa uma **função** de aproximação f , caracterizada por uma configuração específica de um algoritmo (**modelo**)



INTRODUÇÃO

Exemplo de Indução de Hipótese



INTRODUÇÃO

O objetivo em AM é utilizar um **algoritmo de aprendizado** para encontrar uma hipótese capaz de ser utilizada em dados novos (nunca antes vistos): **generalização**

Como obter generalizações a partir de conjuntos **finitos** de observações?

- **Viés Indutivo:** conjunto de suposições (implícitas ou explícitas) realizadas por um algoritmo de AM para realizar a indução de hipóteses
- Causa preferência sobre um conjunto de hipóteses
- Restringe o conjunto de hipóteses que podem ser induzidas por um algoritmo


O **viés indutivo** é um elemento **absolutamente necessário** em um algoritmo de AM para que ocorra aprendizado e generalização!

INTRODUÇÃO



Exemplos de Viés Indutivo de Algoritmos de AM:

- Viés de **Representação**: define o formalismo utilizado para representar uma hipótese. Define (limita) a capacidade de expressar funções e codificar informação
 - Define o **Espaço de Hipóteses**

Redes Neurais



Árvores de Decisão



INTRODUÇÃO

Exemplos de Viés Indutivo de Algoritmos de AM:

- Viés de **Busca**: define como o algoritmo pesquisa por hipóteses e as prioriza dentro do espaço de hipóteses


▲: Modelo Ideal

▲: Melhor modelo possível para algoritmo

▲: Modelo obtido com algoritmo

Não há garantias de:

- O espaço de busca contemplar o modelo ideal
- Encontrar o melhor modelo de um algoritmo



INTRODUÇÃO

Existem diferentes algoritmos de aprendizado, e cada um apresenta um conjunto de vieses indutivos diferentes... **Como escolher qual algoritmo utilizar?**

No Free Lunch Theorem: não existe um algoritmo com melhor desempenho universal

- Não é possível estabelecer *a priori* qual método de ML será melhor para a resolução de um problema específico, pois não há um algoritmo que tenha desempenho superior para todos os problemas de decisão



É preciso ter conhecimento prévio sobre:

- O problema
- A distribuição dos dados
- Avaliação (correta) de modelos

INTRODUÇÃO

Voltando ao conceito de **generalização**...

- Quando utilizamos um algoritmo de aprendizado, estamos procurando por uma hipótese capaz de descrever o comportamento dos dados
 - Podem haver múltiplas hipóteses consistentes com os dados!
 - Como garantir que uma hipótese é boa o suficiente (generaliza)?



■: Tendência real
■: Underfitting
■: Overfitting

INTRODUÇÃO

Existem diversos **regimes de treinamento** possíveis para um sistema de aprendizado:

- **Aprendizado Supervisionado**
- Aprendizado Não-supervisionado
- Aprendizado por Reforço
- ...

Esta taxonomia trata sobre conceitos como:

- Tarefas contempladas
- Feedback para o sistema

INTRODUÇÃO

Aprendizado Supervisionado:


- Conjunto de dados: pares $\{\mathbf{x}, y\}$, atributos preditivos e atributo alvo
- Usar informações contidas nos atributos preditivos para treinar um modelo f capaz de prever valores futuros ou desconhecidos de um atributo alvo
- **Treinamento:** ajustar hipótese através da apresentação sucessiva de instâncias
- **Teste:** aplicar do modelo induzido em dados não-vistos

Tarefas: **Classificação** e **Regressão**

INTRODUÇÃO

Aprendizado Supervisionado: Classificação


- Designar uma instância como pertencente a uma dentre diversas categorias (classes) pré-definidas (atributo alvo), com base em seus atributos preditivos
 - $y = f(x) \in \{y_1, y_2, \dots, y_C\}$, onde C = número de classes
 - $C = 2$: classificação binária
 - $C > 2$: classificação multiclasse
- Algoritmo induz um **classificador**
 - Gera uma **fronteira de decisão**
 - Melhor separabilidade entre classes
 - Boa generalização para novos casos



INTRODUÇÃO

Aprendizado Supervisionado: Regressão

- Atribuir um valor contínuo de saída para uma instância (atributo alvo), com base em seus atributos preditivos
 - $y = f(x) \in \mathbf{R}$
- Algoritmo induz um **regressor**




INTRODUÇÃO

Um aspecto muito relevante sobre modelos de AM é a capacidade de um modelo de ser **interpretável** ou a **explicabilidade** de suas predições

- **Interpretabilidade:** a capacidade de um modelo de explicar (ou apresentar em termos compreensíveis para seres humanos) as suas predições
 - Modelos caixa branca (interpretabilidade intrínseca)

Árvores de Decisão




INTRODUÇÃO

Um aspecto muito relevante sobre modelos de AM é a capacidade de um modelo de ser **interpretável** ou a **explicabilidade** de suas predições

- **Explicabilidade:** coleção de artefatos visuais e/ou interativos que fornecem uma descrição do comportamento de um modelo
 - Modelos caixa preta (interpretabilidade extrínseca)
 - **Explainable Machine learning:** análises post-hoc e técnicas usadas para entender os mecanismos para tomada de decisão de um modelo

Redes Neurais



INTRODUÇÃO

Livros:

- [Mitchell 1997] Capítulo 1
- [Tan et al. 2006] Capítulo 1

Outros:

- [A Few Useful Things to Know About Machine Learning](#)
- [Interpretable Machine Learning Book](#)

AULA 03

APRENDIZADO SUPERVISIONADO - PARTE 2

PROFESSORA: CAMILA ALVES

APRENDIZADO BASEADO EM INSTÂNCIAS

APRENDIZADO BASEADO EM INSTÂNCIAS

Imagine o seguinte cenário: você deseja realizar o diagnóstico de câncer de mama utilizando a seguinte base de dados:

	Radius	Texture	Diagnosis
#1	14	23	Malignant
#2	15	28	Malignant
#3	9	21	Benign

...

#12	13	16	Benign
-----	----	----	---------------

APRENDIZADO BASEADO EM INSTÂNCIAS

Imagine o seguinte cenário: você deseja realizar o diagnóstico de câncer de mama utilizando a seguinte base de dados:

	Radius	Texture	Diagnosis
#1	14	23	Malignant
#2	15	28	Malignant
#3	9	21	Benign

...

#12	13	16	Benign
-----	----	----	--------

17	22	???
----	----	-----



Qual será a classificação
para esta nova instância?

APRENDIZADO BASEADO EM INSTÂNCIAS

Imagine o seguinte cenário: você deseja realizar o diagnóstico de câncer de mama utilizando a seguinte base de dados:

	Radius	Texture	Diagnosis
#1	14	23	Malignant
#2	15	28	Malignant
#3	9	21	Benign


...

#12	13	16	Benign
-----	----	----	--------

	17	22	???
--	----	----	-----



Qual será a classificação para esta nova instância?




Podemos projetar as instâncias do conjunto de treinamento e a nova instância no mesmo espaço

Acabamos de abstrair os detalhes do nosso problema em particular. Será muito mais fácil falar de pontos no espaço

APRENDIZADO BASEADO EM INSTÂNCIAS


Imagine o seguinte cenário: você deseja realizar o diagnóstico de câncer de mama utilizando a seguinte base de dados:

Região do espaço de entrada com predominância de exemplos do tipo “Maligno”





APRENDIZADO BASEADO EM INSTÂNCIAS

Imagine o seguinte cenário: você deseja realizar o diagnóstico de câncer de mama utilizando a seguinte base de dados:



APRENDIZADO BASEADO EM INSTÂNCIAS

Imagine o seguinte cenário: você deseja realizar o diagnóstico de câncer de mama utilizando a seguinte base de dados:



APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias:

- Tem como **premissas** (viés indutivo):
 - Instâncias similares (próximas) pertencem à mesma classe (classificação) ou possuem valores semelhantes de atributo alvo (regressão)
 - *A priori*, todas as características (dimensões) são igualmente importantes

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias:

- Tem como **premissas** (viés indutivo):
 - Instâncias similares (próximas) pertencem à mesma classe (classificação) ou possuem valores semelhantes de atributo alvo (regressão)
 - *A priori*, todas as características (dimensões) são igualmente importantes
- Não constrói um modelo preditivo
- Aprendizado preguiçoso (*lazy*): só observa dados de treinamento quando precisa fazer previsões para um objeto novo (utiliza informações de instâncias similares)

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias:

- Tem como **premissas** (viés indutivo):
 - Instâncias similares (próximas) pertencem à mesma classe (classificação) ou possuem valores semelhantes de atributo alvo (regressão)
 - *A priori*, todas as características (dimensões) são igualmente importantes
- Não constrói um modelo preditivo
- Aprendizado preguiçoso (*lazy*): só observa dados de treinamento quando precisa fazer previsões para um objeto novo (utiliza informações de instâncias similares)

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: O que é **similaridade**?

- É difícil definir similaridade, mas...
“sabemos quando vemos”
- Como descobrir o real sentido de similaridade é uma questão filosófica, vamos partir para uma abordagem mais pragmática
- Como **medir** (quantitativamente) a similaridade entre duas instâncias?



APRENDIZADO BASEADO EM INSTÂNCIAS


Paradigma Baseado em Instâncias: Similaridade VS Dissimilaridade

- **Similaridade:**
 - Medida que indica **nível de semelhança** entre dois objetos
 - Quanto mais semelhantes, maior o seu valor
 - Geralmente, intervalo $[0, 1]$
- **Dissimilaridade:**
 - Medida que indica o **quão diferentes** dois objetos são
 - Quanto mais diferentes, maior o seu valor
 - Geralmente, intervalos $[0, d_{\max}]$ ou $[0, +\infty]$
- Medidas de similaridade e dissimilaridade são chamadas genericamente de **“medidas de proximidade”**

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Proximidade


- Podemos analisar o nível de (dis)similaridade entre instâncias conforme a proximidade delas no espaço de instâncias
- Precisamos definir uma **medida de distância** para quantificar a proximidade entre instâncias, considerando seus vários atributos



APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Definindo Medidas de Distância


- Sejam $\mathbf{x}^1$ e $\mathbf{x}^2$ dois objetos do universo de possíveis objetos em um domínio. A distância (dissimilaridade) entre $\mathbf{x}^1$ e $\mathbf{x}^2$ é um número real denotado por $d(\mathbf{x}^1, \mathbf{x}^2)$



APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Definindo Medidas de Distância

- Quando olhamos dentro de uma destas caixas-pretas, observamos uma função aplicável a duas variáveis. Tais funções podem ser simples ou muito complexas
- É natural se perguntar: que propriedades tais funções têm?




APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Definindo Medidas de Distância

- Quando olhamos dentro de uma destas caixas-pretas, observamos uma função aplicável a duas variáveis. Tais funções podem ser simples ou muito complexas
- É natural se perguntar: que propriedades tais funções têm?

Propriedades:

- $D(A, B) = D(B, A) \rightarrow$ **Simetria**




APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Definindo Medidas de Distância

- Quando olhamos dentro de uma destas caixas-pretas, observamos uma função aplicável a duas variáveis. Tais funções podem ser simples ou muito complexas
- É natural se perguntar: que propriedades tais funções têm?

Propriedades:

- $D(A, B) = D(B, A) \rightarrow$ **Simetria**
- $D(A, A) = 0 \rightarrow$ **Constância da auto-similaridade**




APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Definindo Medidas de Distância

- Quando olhamos dentro de uma destas caixas-pretas, observamos uma função aplicável a duas variáveis. Tais funções podem ser simples ou muito complexas
- É natural se perguntar: que propriedades tais funções têm?

Propriedades:

- $D(A, B) = D(B, A) \rightarrow$ **Simetria**
- $D(A, A) = 0 \rightarrow$ **Constância da auto-similaridade**
- $D(A, B) = 0 \Leftrightarrow A = B \rightarrow$ **Positividade (separação)**




APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Definindo Medidas de Distância

- Quando olhamos dentro de uma destas caixas-pretas, observamos uma função aplicável a duas variáveis. Tais funções podem ser simples ou muito complexas
- É natural se perguntar: que propriedades tais funções têm?

Propriedades:

- $D(A, B) = D(B, A) \rightarrow$ **Simetria**
- $D(A, A) = 0 \rightarrow$ **Constância da auto-similaridade**
- $D(A, B) = 0 \Leftrightarrow A = B \rightarrow$ **Positividade (separação)**
- $D(A, C) \leq D(A, B) + D(B, C) \rightarrow$ **Desigualdade triangular**



APRENDIZADO BASEADO EM INSTÂNCIAS

Intuição por trás das propriedades desejáveis de medidas de distância:

- $D(A, B) = D(B, A) \rightarrow$ **Simetria**
 - “Ana parece com Bia, mas Bia não parece com Ana”
- $D(A, A) = 0 \rightarrow$ **Constância da auto-similaridade**
 - “Ana parece mais com Bia do que com ela mesma”
- $D(A, B) = 0 \Leftrightarrow A = B \rightarrow$ **Positividade (separação)**
 - Existirão objetos diferentes que não seremos capazes de distinguir
- $D(A, C) \leq D(A, B) + D(B, C) \rightarrow$ **Desigualdade triangular**
 - “Ana parece com Bia e Bia parece com Carla, mas Ana não parece com Carla”

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Medidas de Distância

- O tipo de medida de distância que devemos utilizar depende do **tipo dos dados** que estamos trabalhando. Nosso foco será nas medidas amplamente utilizadas:
- Distância Euclidiana
- Distância de Manhattan
- Similaridade do Cosseno
- Distância de Simple-Matching
- Coeficiente de Jaccard
- Tratando atributos categóricos ordinais
- Tratando atributos mistos
- Normalizando valores quantitativos

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Medidas de Distância

- O tipo de medida de distância que devemos utilizar depende do **tipo dos dados** que estamos trabalhando. Nosso foco será nas medidas amplamente utilizadas
- Distância Euclidiana
- Distância de Manhattan
- Similaridade do Cosseno
- Distância de Simple-Matching
- Coeficiente de Jaccard
- **Tratando atributos categóricos ordinais**
- Tratando atributos mistos
- Normalizando valores quantitativos

APRENDIZADO BASEADO EM INSTÂNCIAS

Medidas de Distância: Atributos categóricos ordinais

- Exemplo: tamanho de uma mancha: {pequena, média, grande}
- Ordem dos valores é importante!
- **Normalizar** e utilizar medidas de **proximidade** para **valores contínuos**
 - Exemplo: Distância Euclidiana

Exemplo:

- {pequena, média, grande} $\rightarrow$ (rank - 1) / (num_valores - 1)
- {0, 1/3, 2/3, 1}

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Medidas de Distância

- O tipo de medida de distância que devemos utilizar depende do **tipo dos dados** que estamos trabalhando. Nosso foco será nas medidas amplamente utilizadas
- Distância Euclidiana
- Distância de Manhattan
- Similaridade do Cosseno
- Distância de Simple-Matching
- Coeficiente de Jaccard
- Tratando atributos categóricos ordinais
- **Tratando atributos mistos**
- Normalizando valores quantitativos

APRENDIZADO BASEADO EM INSTÂNCIAS

Medidas de Distância: Atributos mistos

- Quando há uma mistura entre atributos quantitativos e qualitativos, utiliza-se uma composição entre medidas (ex.: Distância Euclidiana + Coeficiente de Jaccard)

	Coeficiente de Jaccard		Distância Euclidiana		
	Profissão	Estado Civil	Idade	Salário	Bom Pagador
#1	Estudante	Solteiro	18	800	Não
#2	Engenheiro	Casado	24	5500	Sim
#3	Mecânico	Casado	53	2750	Sim

...

APRENDIZADO BASEADO EM INSTÂNCIAS

Paradigma Baseado em Instâncias: Medidas de Distância

- O tipo de medida de distância que devemos utilizar depende do **tipo dos dados** que estamos trabalhando. Nosso foco será nas medidas amplamente utilizadas
- Distância Euclidiana
- Distância de Manhattan
- Similaridade do Cosseno
- Distância de Simple-Matching
- Coeficiente de Jaccard
- Tratando atributos categóricos ordinais
- Tratando atributos mistos
- **Normalizando valores quantitativos**

APRENDIZADO BASEADO EM INSTÂNCIAS

Medidas de Distância: Normalizando valores quantitativos

- Quando há uma discrepância no intervalo de valores entre atributos, os atributos possuem impacto proporcional ao seu intervalo
- Estamos dizendo implicitamente que um atributo é mais importante que outros
- Necessário realizar **normalização/estandardização** dos atributos

	Profissão	Estado Civil	Idade	Salário	Bom Pagador
#1	Estudante	Solteiro	18	800	Não
#2	Engenheiro	Casado	24	5500	Sim
#3	Mecanico	Casado	53	2750	Sim

...

AULA 03


APRENDIZADO SUPERVISIONADO - PARTE 3

PROFESSORA: CAMILA ALVES

Algoritmo k-NN


ALGORITMO k-NN

- k-NN: k-vizinhos mais próximos
- Algoritmo de Aprendizado de Máquina baseado em instâncias (e distâncias)
- Utiliza as **k** instâncias mais próximas (similares) para prever o valor do atributo alvo de instâncias nunca antes vistas
- **Classificação:** a classe é definida por um sistema de **votação:** a classe com **maior número de votos** é atribuída à instância



ALGORITMO k-NN

- k-NN: k-vizinhos mais próximos
- Algoritmo de Aprendizado de Máquina baseado em instâncias (e distâncias)
- Utiliza as **k** instâncias mais próximas (similares) para prever o valor do atributo alvo de instâncias nunca antes vistas
- **Classificação:** a classe é definida por um sistema de **votação:** a classe com **maior número de votos** é atribuída à instância
- Necessita de 3 “ingredientes”:
 - Base de dados (treinamento)
 - Medida de (dis)similaridade
 - Valor de **k** (número de vizinhos)



ALGORITMO k-NN

Entradas:

- Conjunto de treinamento $\mathbf{D} = \{(\mathbf{x}_k, y_k)\}^N$
- Medida de distância $d(\mathbf{x}_a, \mathbf{x}_b)$
- Instância de teste $\mathbf{x}_t$
- Número de vizinhos $\mathbf{k}$

ALGORITMO k-NN

Entradas:

- Conjunto de treinamento $\mathbf{D} = \{(\mathbf{x}_k, y_k)\}^N$
- Medida de distância $d(\mathbf{x}_a, \mathbf{x}_b)$
- Instância de teste $\mathbf{x}_t$
- Número de vizinhos $\mathbf{k}$

Saídas:

- Rótulo y_t para a entrada $\mathbf{x}_t$

ALGORITMO k-NN

Entradas:

- Conjunto de treinamento $\mathbf{D} = \{(\mathbf{x}_k, y_k)\}^N$
- Medida de distância $d(\mathbf{x}_a, \mathbf{x}_b)$
- Instância de teste $\mathbf{x}_t$
- Número de vizinhos k

Saídas:

- Rótulo y_t para a entrada $\mathbf{x}_t$

Algoritmo:

1. Para cada instância $\mathbf{x}_k$ em $\mathbf{D}$, faça:
 1. Calcule $d(\mathbf{x}_k, \mathbf{x}_t)$ e armazene
2. Ordene as instâncias em $\mathbf{D}$ de forma crescente, de acordo com as distâncias
3. Selecione as k primeiras instâncias do conjunto $\mathbf{D}$ ordenado
4. Atribua y_t a $\mathbf{x}_t$ o rótulo majoritário dentre as k instâncias selecionadas


ALGORITMO k-NN

Exemplo de execução com **k** = 1

△	13	18	???
---	----	----	-----

- 1. Calcular distâncias
- 2. Ordenar instâncias
- 3. Selecionar k instâncias (1)
- 4. Atribuir rótulo majoritário

	Radius	Texture	Diagnosis	Distance (L2)
#1	14	23	Malignant	
#2	15	28	Malignant	
#3	15	20	Malignant	
#4	16	21	Malignant	
#5	20	22	Malignant	
#6	15	14	Malignant	
#7	9	21	Benign	
#8	9	14	Benign	
#10	11	19	Benign	
#11	9	17	Benign	
#12	13	16	Benign	




ALGORITMO k-NN

Exemplo de execução com **k** = 1

△	13	18	???
---	----	----	-----

- 1. Calcular distâncias
- 2. Ordenar instâncias
- 3. Selecionar k instâncias (1)
- 4. Atribuir rótulo majoritário

	Radius	Texture	Diagnosis	Distance (L2)
#1	14	23	Malignant	5.099
#2	15	28	Malignant	10.1980
#3	15	20	Malignant	2.8284
#4	16	21	Malignant	4.2426
#5	20	22	Malignant	8.0622
#6	15	14	Malignant	4.4721
#7	9	21	Benign	5
#8	9	14	Benign	5.6568
#10	11	19	Benign	2.2360
#11	9	17	Benign	4.1231
#12	13	16	Benign	2




ALGORITMO k-NN

Exemplo de execução com **k** = 1

△	13	18	???
---	----	----	-----

- 1. Calcular distâncias
- 2. **Ordernar instâncias**
- 3. Selecionar k instâncias (1)
- 4. Atribuir rótulo majoritário

	Radius	Texture	Diagnosis	Distance (L2)
#12	13	16	Benign	2
#10	11	19	Benign	2.2360
#3	15	20	Malignant	2.8284
#11	9	17	Benign	4.1231
#4	16	21	Malignant	4.2426
#6	15	14	Malignant	4.4721
#7	9	21	Benign	5
#1	14	23	Malignant	5.099
#8	9	14	Benign	5.6568
#5	20	22	Malignant	8.0622
#2	15	28	Malignant	10.1980




ALGORITMO k-NN

Exemplo de execução com **k** = 1

△	13	18	???
---	----	----	-----

- 1. Calcular distâncias
- 2. Ordenar instâncias
- 3. **Selecionar k instâncias (1)**
- 4. Atribuir rótulo majoritário

	Radius	Texture	Diagnosis	Distance (L2)
#12	13	16	Benign	2
#10	11	19	Benign	2.2360
#3	15	20	Malignant	2.8284
#11	9	17	Benign	4.1231
#4	16	21	Malignant	4.2426
#6	15	14	Malignant	4.4721
#7	9	21	Benign	5
#1	14	23	Malignant	5.099
#8	9	14	Benign	5.6568
#5	20	22	Malignant	8.0622
#2	15	28	Malignant	10.1980




ALGORITMO k-NN

Exemplo de execução com **k** = 1

△	13	18	Benign
---	----	----	--------

- 1. Calcular distâncias
- 2. Ordenar instâncias
- 3. Selecionar k instâncias (1)
- 4. **Atribuir rótulo majoritário**

	Radius	Texture	Diagnosis	Distance (L2)
#12	13	16	Benign	2
#10	11	19	Benign	2.2360
#3	15	20	Malignant	2.8284
#11	9	17	Benign	4.1231
#4	16	21	Malignant	4.2426
#6	15	14	Malignant	4.4721
#7	9	21	Benign	5
#1	14	23	Malignant	5.099
#8	9	14	Benign	5.6568
#5	20	22	Malignant	8.0622
#2	15	28	Malignant	10.1980




ALGORITMO k-NN

Apesar da simplicidade, o algoritmo k-NN com $k = 1$ define uma fronteira de decisão complexa: poliedros convexos com centro em cada instância dos dados de treinamento

- Diagrama de Voronoi

Instância de teste classificada como
“**Benigno**”




Instância de teste classificada como
“**Maligno**”

ALGORITMO k-NN

O algoritmo k-NN é sensível a outliers, especialmente com $k = 1$


- Solução: aumentar o valor de k



ALGORITMO k-NN

O valor do **hiperparâmetro k** precisa ser **definido experimentalmente**, pois impacta o resultado final das predições do modelo

- Valores **pequenos**: função de discriminação muito flexível ($\downarrow$ viés, $\uparrow$ variância)
 - Sensível a ruído, classificação instável (**overfitting**)
- Valores **grandes**: função de discriminação muito robusta ($\uparrow$ viés, $\downarrow$ variância)
 - Robusto a ruído, menos flexível, privilegia classe majoritária (**underfitting**)



O valor de **k** define a **complexidade** do modelo

ALGORITMO k-NN

Na versão básica do algoritmo, a indicação da classe de cada vizinho tem o mesmo peso

- Torna o algoritmo mais sensível ainda à escolha do valor de k
- Geralmente, escolhemos um **valor ímpar** (e diferente do número de classes) para **k** , a fim de evitar empates na decisão a respeito do atributo alvo

ALGORITMO k-NN

Na versão básica do algoritmo, a indicação da classe de cada vizinho tem o mesmo peso

- Torna o algoritmo mais sensível ainda à escolha do valor de k
- Geralmente, escolhemos um **valor ímpar** (e diferente do número de classes) para **k** , a fim de evitar empates na decisão a respeito do atributo alvo

Alternativa: **ponderar cada voto pela respectiva distância de cada instância**

- A contribuição de cada instância é multiplicada por uma **função de ponderação**
- Classe escolhida: maior soma ponderada. Permite valores maiores de **k**

Diagnosis	Distance (L2)	Weighted Distance (1/d)
Benign	2	0.500
Malignant	2.2360	0.448
Malignant	2.8284	0.354

Benign: 0.5

Malignant: $(0.448 + 0.354) = 0.802$

$$\frac{1}{d(x^i, x^j)} \quad \frac{1}{d(x^i, x^j)^2}$$


ALGORITMO k-NN

O algoritmo k-NN é facilmente adaptado para a tarefa de **Regressão**

- Atributo Alvo: **média** (ponderada) dos valores dos k vizinhos mais próximos

Radius	Texture	Survival
13	16	35
11	19	18
15	20	32
9	17	13
16	21	28

...

ALGORITMO k-NN

O algoritmo k-NN é facilmente adaptado para a tarefa de **Regressão**

- Atributo Alvo: **média** (ponderada) dos valores dos k vizinhos mais próximos
- Exemplo: **k** = 3

$$\frac{1}{d(x^i, x^j)}$$

Radius	Texture	Survival
13	16	35
11	19	18
15	20	32
9	17	13
16	21	28

...

ALGORITMO k-NN

O algoritmo k-NN é facilmente adaptado para a tarefa de **Regressão**

- Atributo Alvo: **média** (ponderada) dos valores dos k vizinhos mais próximos
- Exemplo: **k** = 3

$$\frac{1}{d(x^i, x^j)}$$

Radius	Texture	Survival	Distance (L2)	Weighted Distance (1/d)
13	16	35	2	0.5
11	19	18	2.2360	0.4472
15	20	32	2.8284	0.3535
9	17	13	4.1231	0.2425
16	21	28	4.2426	0.2357

...

ALGORITMO k-NN

O algoritmo k-NN é facilmente adaptado para a tarefa de **Regressão**

- Atributo Alvo: **média** (ponderada) dos valores dos k vizinhos mais próximos
- Exemplo: **k** = 3

$$\frac{1}{d(x^i, x^j)}$$

Radius	Texture	Survival	Distance (L2)	Weighted Distance (1/d)
13	16	35	2	0.5
11	19	18	2.2360	0.4472
15	20	32	2.8284	0.3535
9	17	13	4.1231	0.2425
16	21	28	4.2426	0.2357

...

$$\begin{aligned} y &= (0.5 \cdot 35 + 0.4472 \cdot 18 + 0.3535 \cdot 32) / (0.5 + 0.4472 + 0.3535) \\ &= (17.5 + 8.0496 + 11.3120) / 1.3007 \\ &= 36.8616 / 1.3007 \\ &= 28.3398 \end{aligned}$$

ALGORITMO k-NN

É extremamente importante realizar uma etapa de pré-processamento!

- O k-NN é afetado pela presença de **atributos irrelevantes ou redundantes**
 - Causam distorções no cálculo da distância

ALGORITMO k-NN



É extremamente importante realizar uma etapa de pré-processamento!

- O k-NN é afetado pela presença de **atributos irrelevantes ou redundantes**
 - Causam distorções no cálculo da distância
- É impactado pela **alta dimensionalidade** de dados (muitos atributos)
 - Em espaços altamente dimensionais (ex.: 300 atributos), a diferença entre vizinhos se torna mais sutil (pequenas variações causam baixo impacto)

ALGORITMO k-NN

É extremamente importante realizar uma etapa de pré-processamento!

- O k-NN é afetado pela presença de **atributos irrelevantes ou redundantes**
 - Causam distorções no cálculo da distância
- É impactado pela **alta dimensionalidade** de dados (muitos atributos)
 - Em espaços altamente dimensionais (ex.: 300 atributos), a diferença entre vizinhos se torna mais sutil (pequenas variações causam baixo impacto)
- É sensível às **unidades de medida** dos atributos (solução: **normalização**)



ALGORITMO k-NN

O algoritmo k-NN é um classificador *lazy*, ou seja, não constrói um modelo e realiza o processamento das instâncias para cada nova instância

- O processo de predição para novos objetos é **computacionalmente custoso**

Possível solução: **estruturas de dados mais eficientes**

- Reduzir o número de cálculos de distância necessários
- Exemplo: KD-Tree

ALGORITMO k-NN

Interpretabilidade e Explicabilidade do algoritmo k-NN:

- Algoritmo *lazy*: não constrói “modelo”. Não é interpretável em um nível **global**
- Realiza previsões baseado em uma vizinhança: **interpretação local**
 - Podemos recuperar os k vizinhos de uma nova instância para tentar interpretar o resultado da previsão do atributo alvo

O **nível de interpretabilidade** do modelo depende da **complexidade e quantidade** dos **atributos preditivos** do conjunto de dados

- Ex.: se uma instância contém centenas ou milhares de atributos, provavelmente será difícil interpretar as previsões do modelo

ALGORITMO k-NN

- O algoritmo k-NN é extremamente simples, mas ainda assim é capaz de gerar um “modelo” com **fronteira de decisão não-linear**
- Funciona para Classificação e Regressão
- Treinamento: somente armazenamento
- Predição: custoso

Características sensíveis ao projeto:

- Processo de pré-processamento é vital para o bom funcionamento
- Balanceamento de classes: afetado por distribuições de classes desproporcionais
- Valor do hiperparâmetro **k** define a complexidade do modelo
- Escolha da medida de (dis)similaridade depende dos dados

ALGORITMO k-NN

Livros:

- [Tan et al. 2006] Seção 5.2
- [Faceli et al. 2011] Capítulo 4

Código:

- <https://scikit-learn.org/stable/modules/neighbors.html#nearest-neighbors>