

Estudo de Caso 3 – Parte 1:

Quanto vale alugar um apê?

A startup AlugaFácil deseja automatizar suas recomendações de preços de aluguel com base em características dos imóveis. Eles também querem prever se um imóvel é caro ou barato com base na média da região.

Você e sua equipe foram contratados como cientistas de dados para criar e avaliar esse modelo.

Dataset fornecido:

O arquivo dados_apartamentos.csv contém aproximadamente 1000 registros com as seguintes colunas:

- area_m2
- quartos
- banheiros
- garagem
- distancia_centro_km
- andar
- preco_aluguel

Objetivos:

1. Criar um modelo de regressão linear para prever o valor do aluguel.
2. Classificar os imóveis em "caro" ou "barato" com base na média geral.
3. Avaliar a performance do modelo de classificação.
4. Propor ajustes para melhorar a performance.

Tarefas por grupo:

Parte 1: Análise exploratória

- Carregue os dados com pandas
- Verifique valores ausentes, tipos e estatísticas básicas
- Faça gráficos de dispersão entre as variáveis independentes e o preço
- Há alguma correlação aparente?

Parte 2: Regressão Linear

- Crie um modelo de regressão linear com scikit-learn
- Use as variáveis: area_m2, quartos, banheiros, garagem e distancia_centro_km
- Separe os dados em treino e teste (80/20)
- Faça previsões no conjunto de teste

- Meça a performance com `mean_absolute_error` e `r2_score`
- Interprete os coeficientes do modelo

Parte 3: Classificação

- Crie uma nova coluna "caro":
`df["caro"] = df["preco_aluguel"] > df["preco_aluguel"].mean()`
- Treine um modelo de regressão logística
- Meça a performance com:
 - Acurácia
 - Precisão
 - Recall
 - Matriz de confusão

Parte 4: Discussão em grupo

- O modelo previu bem o valor do aluguel?
- O modelo classificou bem os imóveis?
- Que ajustes poderiam melhorar o desempenho?

Parte 5: Entrega

- Notebook do Google Colab com:
 - Código executado
 - Gráficos
 - Respostas escritas em formato de relatório

Dataset: `dados_apartamentos.csv`

Estudo de Caso 3 – Parte 2: Análise de Fatores que Influenciam o Número de Óbitos por Covid-19

Durante a pandemia da Covid-19, diferentes regiões do Brasil apresentaram taxas muito diferentes de mortalidade. Governos e pesquisadores passaram a investigar quais fatores estavam mais associados ao número de óbitos. Seu grupo foi contratado por uma organização de saúde pública para construir um modelo preditivo baseado em dados reais.

Você recebeu um conjunto de dados com informações de **1000 municípios brasileiros**, contendo as seguintes variáveis:

- `obitos_covid`: número total de óbitos registrados por Covid-19 (variável dependente)
- `populacao`: população total do município
- `densidade_demografica`: número de habitantes por km²
- `idosos_pct`: percentual da população com mais de 60 anos
- `leitos_uti`: número de leitos de UTI disponíveis no município
- `indice_isolamento`: índice médio de isolamento social durante os primeiros 6 meses da pandemia (0 a 1)
- `renda_media`: renda média mensal da população (em R\$)

Tarefas

1. **Importação e exploração**
 - Carregue o dataset.
 - Verifique se há valores nulos.
 - Faça uma análise descritiva das variáveis.
 - Plote histogramas e gráficos de dispersão.
2. **Criação do modelo**
 - Utilize regressão linear múltipla para prever `obitos_covid`.
 - Separe o dataset em treino (80%) e teste (20%).
 - Treine o modelo e exiba os coeficientes de cada variável.
3. **Avaliação**
 - Calcule o erro médio absoluto (MAE).
 - Calcule o erro quadrático médio (MSE).
 - Calcule o R².
 - Interprete os resultados. O modelo tem bom desempenho?
4. **Interpretação**
 - Qual variável teve maior impacto positivo nos óbitos? E qual teve impacto negativo?
 - O índice de isolamento social parece ter ajudado a reduzir o número de óbitos? Justifique.

- Há alguma variável que não parece ter relação com os óbitos? Qual?
- 5. **Discussão**
 - Quais variáveis você incluiria a mais no modelo, se tivesse acesso?
 - Quais limitações esse tipo de análise pode ter?
 - Você acredita que esse modelo poderia ser usado para tomar decisões políticas? Por quê?
- 6. **Entrega**
 - Notebook do Google Colab com:
 - Código executado
 - Gráficos
 - Respostas escritas em formato de relatório

Dataset: Dados_Covid_-_Regress_o_Linear.csv