

Estudo de Caso 6 – NLP em Avaliações de Produtos

Introdução:

Você é um cientista de dados recém-contratado por uma startup de tecnologia que deseja entender melhor a experiência dos clientes com produtos vendidos online. Sua missão é analisar milhares de avaliações reais deixadas por consumidores no site da Amazon.

Esses textos contêm informações valiosas sobre satisfação, frustração, elogios e críticas que podem ajudar a empresa a melhorar suas recomendações e estratégias de marketing.

Para isso, você vai aplicar técnicas de Processamento de Linguagem Natural (NLP) para limpar, transformar e visualizar esses dados, extraindo insights que poderão ser usados em futuras análises e modelos de previsão de sentimento.

Objetivo:

Analisar avaliações reais de consumidores sobre produtos da Amazon e aplicar técnicas de Processamento de Linguagem Natural (NLP) para extrair padrões, limpar os textos e visualizar as informações mais relevantes.

Dataset:

<https://www.kaggle.com/datasets/sampaiovitor/avaliaes-em-portugus-amazon-e-mercado-livre>

O arquivo '**am_scrape_final.csv**' contém colunas como:

- Search Query: termo de busca utilizado
- Product Title: nome do produto
- Link: link da página do produto na Amazon
- Review: avaliação escrita por um consumidor

Inspiração:

Para realizar este trabalho você poderá se inspirar nos seguintes notebooks:

- Notebook `pr_processamento_para_nlp_CEUB_inicial.ipynb` dentro do diretório **Aula 16 - 26/06/2026 - Processamento de Linguagem Natural**
- Exploring and Learning NLP| Python
<https://www.kaggle.com/code/anderaraujo/exploring-and-learning-nlp-python/notebook>
- Pré-processamento para NLP
<https://www.kaggle.com/code/cassioall/pr-processamento-para-nlp/notebook>
- Introdução ao PNL com Python
<https://github.com/alura-cursos/introducao-ao-pln-com-python/blob/master/Aula5.ipynb>

Tarefas propostas:

1. Limpar os textos da coluna 'Review': remover pontuações, números, símbolos, espaços em branco, etc.
2. Remover palavras irrelevantes (stopwords) usando listas em português.
3. Aplicar lematização e stemização nos textos.
4. Criar uma nuvem de palavras para visualizar os termos mais frequentes nas avaliações.
5. Transformar as avaliações para formato numérico utilizando técnicas como Bag of Words (CountVectorizer) ou TF-IDF (TfidfVectorizer).
6. **(Opcional)** Treinar um modelo de classificação de sentimento com base nas reviews, utilizando algoritmos como RandomForestClassifier ou MLPClassifier.