

Árvores de Decisão

Árvores de Decisão

- Abordagem de modelagem preditiva para problemas de **classificação** e **regressão**

Árvores de Decisão


- Abordagem de modelagem preditiva para problemas de **classificação** e **regressão**
- Representam graficamente uma série de testes encadeados aplicados sobre atributos do domínio, que levam a uma decisão final sobre a classe (predição)

Árvores de Decisão

- Abordagem de modelagem preditiva para problemas de **classificação** e **regressão**
- Representam graficamente uma série de testes encadeados aplicados sobre atributos do domínio, que levam a uma decisão final sobre a classe (predição)
- Modelo representado por um **grafo acíclico direcionado**
 - Conjunto de regras “**IF... ELSE**”

Árvores de Decisão

- Abordagem de modelagem preditiva para problemas de **classificação** e **regressão**
- Representam graficamente uma série de testes encadeados aplicados sobre atributos do domínio, que levam a uma decisão final sobre a classe (predição)
- Modelo representado por um **grafo acíclico direcionado**
 - Conjunto de regras “**IF... ELSE**”




Árvores de Decisão

- Abordagem de modelagem preditiva para problemas de **classificação** e **regressão**
- Representam graficamente uma série de testes encadeados aplicados sobre atributos do domínio, que levam a uma decisão final sobre a classe (predição)
- Modelo representado por um **grafo acíclico direcionado**
 - Conjunto de regras “**IF... ELSE**”

Raiz

Nodos Internos

Nodos Folha




Árvores de Decisão

- Árvore de decisão é um modelo em estrutura de árvore no qual:

Raiz

Nodos Internos

Nodos Folha




Árvores de Decisão

- Árvore de decisão é um modelo em estrutura de árvore no qual:
 - Cada **nó não-folha** denota um teste sobre determinado atributo

Raiz

Nodos Internos

Nodos Folha




Árvores de Decisão

- Árvore de decisão é um modelo em estrutura de árvore no qual:
 - Cada **nó não-folha** denota um teste sobre determinado atributo
 - Cada **ramo descendente** corresponde a um possível valor do atributo testado

Raiz

Nodos Internos

Nodos Folha




Árvores de Decisão

- Árvore de decisão é um modelo em estrutura de árvore no qual:
 - Cada **nó não-folha** denota um teste sobre determinado atributo
 - Cada **ramo descendente** corresponde a um possível valor do atributo testado
 - Cada **folha** está associada a uma classe

Raiz

Nodos Internos

Nodos Folha




Árvores de Decisão

- Árvore de decisão é um modelo em estrutura de árvore no qual:
 - Cada **nó não-folha** denota um teste sobre determinado atributo
 - Cada **ramo descendente** corresponde a um possível valor do atributo testado
 - Cada **folha** está associada a uma classe
 - Um percurso da raiz até uma folha define uma regra de classificação

Raiz

Nodos Internos

Nodos Folha



Árvores de Decisão


- Árvores de decisão buscam definir uma fronteira de decisão gerando partições recursivas no espaço de entrada, buscando por regiões com menos impurezas possível

Árvores de Decisão

- Árvores de decisão buscam definir uma fronteira de decisão gerando partições recursivas no espaço de entrada, buscando por regiões com menos impurezas possível
 - Essas partições derivam de testes sobre os atributos

Árvores de Decisão

- Árvores de decisão buscam definir uma fronteira de decisão gerando partições recursivas no espaço de entrada, buscando por regiões com menos impurezas possível
 - Essas partições derivam de testes sobre os atributos



fronteira de decisão

Indução de Árvores de Decisão

- A indução é o processo de raciocínio sobre um dado conjunto de informações para concluir princípios gerais ou regras

Indução de Árvores de Decisão

- A indução é o processo de raciocínio sobre um dado conjunto de informações para concluir princípios gerais ou regras
- Existem muitas heurísticas para gerar árvores
 - Top-Down
 - Bottom-up
 - Híbrida
 - Algoritmos evolutivos

Indução de Árvores de Decisão

- A indução é o processo de raciocínio sobre um dado conjunto de informações para concluir princípios gerais ou regras
- Existem muitas heurísticas para gerar árvores
 - Top-Down
 - Bottom-up
 - Híbrida
 - Algoritmos evolutivos
- De forma geral, o procedimento padrão para indução de uma árvore é o **Top-Down**

Indução de Árvores de Decisão

- **Algoritmo de Hunt** (Top-Down (recursivo)):
 - D_t : conjunto de instâncias que chega até o nodo t
 - $y = \{y_1, \dots, y_c\}$: rótulos das classes

Indução de Árvores de Decisão

- **Algoritmo de Hunt** (Top-Down (recursivo)):
 - D_t : conjunto de instâncias que chega até o nodo t
 - $y = \{y_1, \dots, y_c\}$: rótulos das classes
 - **Passo 1:** se todas as instâncias D_t pertencem à mesma classe y_i , t é um nodo folha (classe i)

Indução de Árvores de Decisão

- **Algoritmo de Hunt** (Top-Down (recursivo)):
 - D_t : conjunto de instâncias que chega até o nodo t
 - $y = \{y_1, \dots, y_c\}$: rótulos das classes
 - **Passo 1:** se todas as instâncias D_t pertencem à mesma classe y_i , t é um nodo folha (classe i)
 - **Passo 2:** Se D_t não é homogêneo, selecionar **melhor atributo**, criar novo nodo e dividir instâncias de acordo com os valores do atributo. Aplicar recursivamente.

Indução de Árvores de Decisão

- **Algoritmo de Hunt** (Top-Down (recursivo)):
 - D_t : conjunto de instâncias que chega até o nodo t
 - $y = \{y_1, \dots, y_c\}$: rótulos das classes
 - **Passo 1:** se todas as instâncias D_t pertencem à mesma classe y_i , t é um nodo folha (classe i)
 - **Passo 2:** Se D_t não é homogêneo, selecionar **melhor atributo**, criar novo nodo e dividir instâncias de acordo com os valores do atributo. Aplicar recursivamente.
- Divisão e conquista: dividir o problema original em subproblemas mais simples, aplicando recursivamente esta estratégia

Indução de Árvores de Decisão

- **Algoritmo de Hunt** (Top-Down (recursivo)):
 - D_t : conjunto de instâncias que chega até o nodo t
 - $y = \{y_1, \dots, y_c\}$: rótulos das classes
 - **Passo 1:** se todas as instâncias D_t pertencem à mesma classe y_i , t é um nodo folha (classe i)
 - **Passo 2:** Se D_t não é homogêneo, selecionar **melhor atributo**, criar novo nodo e dividir instâncias de acordo com os valores do atributo. Aplicar recursivamente.
- Divisão e conquista: dividir o problema original em subproblemas mais simples, aplicando recursivamente esta estratégia
- Algoritmo guloso: escolher a melhor subdivisão **local**

Indução de Árvores de Decisão

- **Algoritmo de Hunt** (Top-Down (recursivo)):
 - D_t : conjunto de instâncias que chega até o nodo t
 - $y = \{y_1, \dots, y_c\}$: rótulos das classes
 - **Passo 1:** se todas as instâncias D_t pertencem à mesma classe y_i , t é um nodo folha (classe i)
 - **Passo 2:** Se D_t não é homogêneo, selecionar **melhor atributo**, criar novo nodo e dividir instâncias de acordo com os valores do atributo. Aplicar recursivamente.
- Divisão e conquista: dividir o problema original em subproblemas mais simples, aplicando recursivamente esta estratégia
- Algoritmo guloso: escolher a melhor subdivisão **local**
- Não há **backtracking** (impureza é minimizada localmente em cada nó)

Indução de Árvores de Decisão

- **Critérios de parada para Indução Top-Down**

Indução de Árvores de Decisão

- **Critérios de parada para Indução Top-Down**
 - Homogeneidade da classe (todas as instâncias forem da mesma classe)

Indução de Árvores de Decisão

- **Critérios de parada para Indução Top-Down**
 - Homogeneidade da classe (todas as instâncias forem da mesma classe)
 - Homogeneidade das instâncias (todos os atributos forem iguais)

Indução de Árvores de Decisão

- **Critérios de parada para Indução Top-Down**
 - Homogeneidade da classe (todas as instâncias forem da mesma classe)
 - Homogeneidade das instâncias (todos os atributos forem iguais)
 - Atingir valor satisfatório do critério de divisão

Indução de Árvores de Decisão

- **Critérios de parada para Indução Top-Down**
 - Homogeneidade da classe (todas as instâncias forem da mesma classe)
 - Homogeneidade das instâncias (todos os atributos forem iguais)
 - Atingir valor satisfatório do critério de divisão
 - Atingir profundidade máxima

Árvores de Decisão

Cenário

- Você é professor da disciplina de AM e deseja saber quais fatores determinam a aprovação/reprovação dos alunos
 - Coletar dados (abordagem orientada a dados)


Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não

Árvores de Decisão

Cenário

- Você é professor da disciplina de AM e deseja saber quais fatores determinam a aprovação/reprovação dos alunos
 - Coletar dados (abordagem orientada a dados)
 - Algoritmo de Indução (Top-Down)

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação



Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não



Árvores de Decisão

Impureza



- Dados estes dois atributos, qual separa melhor os dados?



Árvores de Decisão


Impureza

- Dados estes dois atributos, qual separa melhor os dados?
 - Nenhum separa perfeitamente os dados (**impureza**)
 - Existem várias medidas de impureza



Árvores de Decisão

Impureza



Critérios de seleção de atributos

- Principais critérios de seleção de atributos:
 - Ganho de Informação - Algoritmo ID3 (Entropia)
 - Razão de Ganho - Algoritmo C4.5
 - Índice Gini - Algoritmo CART

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Baseado no conceito de **entropia**

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Baseado no conceito de **entropia**
 - Medida do grau de aleatoriedade de uma variável
 - No caso de árvores de decisão está associado à dificuldade de prever o atributo alvo a partir do atributo analisado. Isto é, entropia mede o grau de certeza que temos sobre determinado evento.

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Baseado no conceito de **entropia**
 - Medida do grau de aleatoriedade de uma variável.
 - No caso de árvores de decisão está associado à dificuldade de prever o atributo alvo a partir do atributo analisado. Isto é, entropia mede o grau de certeza que temos sobre determinado evento.

$$Entropy(P) = - \sum_{i=1}^n p_i \log_2(p_i)$$

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Baseado no conceito de **entropia**
 - Medida do grau de aleatoriedade de uma variável.
 - No caso de árvores de decisão está associado à dificuldade de prever o atributo alvo a partir do atributo analisado. Isto é, entropia mede o grau de certeza que temos sobre determinado evento.

$$Entropy(P) = - \sum_{i=1}^n p_i \log_2(p_i)$$

- P_i : probabilidade de um exemplo pertencer a classe y_i , estimada a partir das proporções de instâncias em cada classe

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Baseado no conceito de **entropia**
 - Medida do grau de aleatoriedade de uma variável.
 - No caso de árvores de decisão está associado à dificuldade de prever o atributo alvo a partir do atributo analisado. Isto é, entropia mede o grau de certeza que temos sobre determinado evento.

$$Entropy(P) = - \sum_{i=1}^n p_i \log_2(p_i)$$

- P_i : probabilidade de um exemplo pertencer a classe y_i , estimada a partir das proporções de instâncias em cada classe
- Quanto mais alta a entropia, mais difícil de se derivar uma conclusão a partir dos dados

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

$$Entropy(t) = - \sum_j (j|t) \log_2(j|t)$$

C1	0
C2	6

C1	1
C2	5

C1	2
C2	4

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

$$Entropy(t) = - \sum_j (j|t) \log_2(j|t)$$

C1	0
C2	6

$$P(C1) = 0/6 = 0 \quad P(C2) = 6/6 = 1$$

$$Entropy = - 0 \log 0 - 1 \log 1 = 0 - 0 = \mathbf{0}$$

C1	1
C2	5

$$P(C1) = 1/6 \quad P(C2) = 5/6$$

$$Entropy = - (1/6) \log_2 (1/6) - (5/6) \log_2 (5/6) = \mathbf{0.65}$$

C1	2
C2	4

$$P(C1) = 2/6 \quad P(C2) = 4/6$$

$$Entropy = - (2/6) \log_2 (2/6) - (4/6) \log_2 (4/6) = \mathbf{0.92}$$

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Supondo uma divisão dos dados com base em um atributo **A**, a partir do qual gera-se o subconjunto **D_j**

$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j)$$

j = subconjunto

$Info(D_j)$ = cálculo da entropia restrito ao subconjunto D_j (probabilidade de observar uma classe dado um valor do atributo)

Ponderar ganho de informação da partição de acordo com a proporção de exemplos em relação ao conjunto original

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Ganho de informação estimado com a divisão do nó no atributo A:

$$Gain(A) = Info(D) - Info_A(D).$$


$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i),$$


$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j).$$

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Ganho de informação estimado com a divisão do nó no atributo A:

$$Gain(A) = Info(D) - Info_A(D).$$


$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i),$$


$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j).$$

- O ganho de informação é calculado para cada partição gerada, de forma recursiva

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Ganho de informação estimado com a divisão do nó no atributo A:

$$Gain(A) = Info(D) - Info_A(D).$$


$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i),$$


$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j).$$

- O ganho de informação é calculado para cada partição gerada, de forma recursiva
- Visa maximizar o **ganho de informação**. Isto é, visa minimizar a média ponderada das entropias dos nós filhos

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

- Ganho de informação estimado com a divisão do nó no atributo A:

$$Gain(A) = Info(D) - Info_A(D).$$


$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i),$$

$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j).$$

- O ganho de informação é calculado para cada partição gerada, de forma recursiva
- Visa maximizar o **ganho de informação**. Isto é, visa minimizar a média ponderada das entropias dos nós filhos
- O atributo que **maximizar** o ganho de informação é selecionado para divisão de um novo nó

Critérios de seleção de atributos

Ganho de Informação (Algoritmo ID3)

$$Gain(A) = Info(D) - Info_A(D).$$


$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i),$$


$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j).$$

- Desvantagem: é tendencioso à divisões com número grande de partições, cada uma sendo pequena porém pura

Critérios de seleção de atributos

- Principais critérios de seleção de atributos:
 - Ganho de Informação - Algoritmo ID3 (Entropia)
 - **Razão de Ganho - Algoritmo C4.5**
 - Índice Gini - Algoritmo CART

Critérios de seleção de atributos

Razão de Ganho

- Utilizado no **algoritmo C4.5**
- Representa o potencial de informação gerado através da divisão dos dados em v partições, correspondendo aos v valores possíveis do atributo A

Critérios de seleção de atributos

Razão de Ganho

- Utilizado no **algoritmo C4.5**
- Representa o potencial de informação gerado através da divisão dos dados em $\mathbf{v}$ partições, correspondendo aos $\mathbf{v}$ valores possíveis do atributo A

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}.$$

$$SplitInfo_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2 \left(\frac{|D_j|}{|D|} \right).$$

Critérios de seleção de atributos

Razão de Ganho

- Utilizado no **algoritmo C4.5**
- Representa o potencial de informação gerado através da divisão dos dados em $\mathbf{v}$ partições, correspondendo aos $\mathbf{v}$ valores possíveis do atributo A

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}.$$

$$SplitInfo_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2 \left(\frac{|D_j|}{|D|} \right).$$

- Ajusta o ganho de informação pela entropia do particionamento (SplitInfo).

Critérios de seleção de atributos

Razão de Ganho

- Utilizado no **algoritmo C4.5**
- Representa o potencial de informação gerado através da divisão dos dados em v partições, correspondendo aos v valores possíveis do atributo A

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}.$$

$$SplitInfo_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2 \left(\frac{|D_j|}{|D|} \right).$$

- Ajusta o ganho de informação pela entropia do particionamento (SplitInfo).
 - Quanto maior a entropia do particionamento, maior a penalidade do ganho de informação.

Critérios de seleção de atributos

- Principais critérios de seleção de atributos:
 - Ganho de Informação - Algoritmo ID3 (Entropia)
 - Razão de Ganho - Algoritmo C4.5
 - **Índice Gini - Algoritmo CART**

Critérios de seleção de atributos

Índice Gini

- Mede a impureza dos dados de treinamento (ou uma partição)

Critérios de seleção de atributos

Índice Gini

- Mede a impureza dos dados de treinamento (ou uma partição)
- É usado para medir a probabilidade de uma instância pertencer à classe estimada

Critérios de seleção de atributos

Índice Gini

- Mede a impureza dos dados de treinamento (ou uma partição)
- É usado para medir a probabilidade de uma instância pertencer à classe estimada

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$

Critérios de seleção de atributos

Índice Gini

- Mede a impureza dos dados de treinamento (ou uma partição)
- É usado para medir a probabilidade de uma instância pertencer à classe estimada

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$

- t : nodo em questão
- C : número de classes
- i : classe atual
- $p(i|t)$: probabilidade de uma classe i em um nodo t

Critérios de seleção de atributos

Índice Gini

- Mede a impureza dos dados de treinamento (ou uma partição)
- É usado para medir a probabilidade de uma instância pertencer à classe estimada

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$

- t : nodo em questão
 - C: número de classes
 - i: classe atual
 - p(i|t): probabilidade de uma classe i em um nodo t
- Valor **máximo**: $1 - (1/c)$. Classes equiprováveis

Critérios de seleção de atributos

Índice Gini

- Mede a impureza dos dados de treinamento (ou uma partição)
- É usado para medir a probabilidade de uma instância pertencer à classe estimada

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$

- t : nodo em questão
 - C: número de classes
 - i: classe atual
 - p(i|t): probabilidade de uma classe i em um nodo t
- Valor **máximo**: $1 - (1/c)$. Classes equiprováveis
 - Valor **mínimo**: 0. Todas as instâncias da mesma classe
 - **Menor = melhor**

Critérios de seleção de atributos

Índice Gini

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$

C1	0
C2	6

C1	1
C2	5

C1	2
C2	4

Cr terios de sele  o de atributos

 ndice Gini

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$

C1	0
C2	6

$$P(C1) = 0/6 = 0 \qquad P(C2) = 6/6 = 1$$

$$\text{Gini} = 1 - P(C1)^2 - P(C2)^2 = 1 - 0 - 1 = \mathbf{0}$$

C1	1
C2	5

$$P(C1) = 1/6 \qquad P(C2) = 5/6$$

$$\text{Gini} = 1 - (1/6)^2 - (5/6)^2 = \mathbf{0.268}$$

C1	2
C2	4

$$P(C1) = 2/6 \qquad P(C2) = 4/6$$


$$\text{Gini} = 1 - (2/6)^2 - (4/6)^2 = \mathbf{0.444}$$

Árvores de Decisão

Impureza - Índice Gini

- Começar calculando a impureza dos nodos folha

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i | t)^2$$



$$\text{Gini} = 0.375$$

$$\begin{aligned} \text{Gini} &= 1 - \left(\left(\frac{1}{1+3} \right)^2 + \left(\frac{3}{1+3} \right)^2 \right) \\ &= 1 - \left(\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right) \\ &= 1 - (0.0625 + 0.5625) \\ &= 1 - (0.625) \\ &= \mathbf{0.375} \end{aligned}$$


Árvores de Decisão

Impureza - Índice Gini

- Começar calculando a impureza dos nodos folha

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i | t)^2$$

$$\begin{aligned} \text{Gini} &= 1 - ((2/(2+1))^2 + (1/(2+1))^2) \\ &= 1 - ((2/3)^2 + (1/3)^2) \\ &= 1 - (0.4444 + 0.1111) \\ &= 1 - (0.5555) \\ &= \mathbf{0.4445} \end{aligned}$$



$$\text{Gini} = 0.375$$

$$\text{Gini} = 0.444$$

Árvores de Decisão

Impureza - Índice Gini

- Começar calculando a impureza dos nodos folha

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i \mid t)^2$$


a : atributo em questão

K: número de classes

i: nodo atual

ni: número de instâncias no nodo filho i

n: número de instâncias do nó pai



Gini = 0.375

Gini = 0.444

Árvores de Decisão


Impureza - Índice Gini

- Começar calculando a impureza dos nodos folha

$$\text{Gini}(t) = 1 - \sum_{i=1}^C p(i | t)^2$$

$$n = 7$$

$$\begin{aligned} \text{Gini} &= ((4/7) * 0.375 + (3/7) * 0.444) \\ &= (0.571 * 0.375 + 0.428 * 0.444) \\ &= 0.404 \end{aligned}$$



$$\text{Gini} = 0.375$$



$$\text{Gini} = 0.444$$

Árvores de Decisão

Impureza - Índice Gini

- Depois, calcular impureza do atributo

$$\text{Gini}(a) = \sum_{i=1}^K \frac{n_i}{n} \text{Gini}(i)$$




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não



O processo para calcular a impureza de atributos contínuos é mais complexo

- Decisão baseada em **limiar**

Árvores de Decisão

Impureza - Índice Gini (Atributos Contínuos)

- Ordenar linhas pelos valores (crescente)

Horas de Estudo	Aprovado
2	Não
5	Não
6	Sim
12	Sim
14	Sim
20	Não
30	Não

Árvores de Decisão

Impureza - Índice Gini (Atributos Contínuos)

- Ordenar linhas pelos valores (crescente)
- Calcular médias para valores intermediários

Horas de Estudo	Aprovado
2	Não
5	Não
6	Sim
12	Sim
14	Sim
20	Não
30	Não

Média	3.5	5.5	9	13	17	25
Gini						


Árvores de Decisão

Impureza - Índice Gini (Atributos Contínuos)

- Ordenar linhas pelos valores (crescente)
- Calcular médias para valores intermediários
- Calcular impureza para cada valor de média

Horas de Estudo	Aprovado
2	Não
5	Não
6	Sim
12	Sim
14	Sim
20	Não
30	Não

Média	3.5	5.5	9	13	17	25
Gini	0.429					



Árvores de Decisão

Impureza - Índice Gini (Atributos Contínuos)

- Ordenar linhas pelos valores (crescente)
- Calcular médias para valores intermediários
- Calcular impureza para cada valor de média

Horas de Estudo	Aprovado
2	Não
5	Não
6	Sim
12	Sim
14	Sim
20	Não
30	Não

Média	3.5	5.5	9	13	17	25
Gini	0.429	0.343	0.476	0.476	0.343	0.429

Árvores de Decisão

Impureza - Índice Gini (Atributos Contínuos)

- Ordenar linhas pelos valores (crescente)
- Calcular médias para valores intermediários
- Calcular impureza para cada valor de média

Horas de Estudo	Aprovado
2	Não
5	Não
6	Sim
12	Sim
14	Sim
20	Não
30	Não

Média	3.5	5.5	9	13	17	25
Gini	0.429	0.343	0.476	0.476	0.343	0.429


Valores repetidos: podemos escolher qualquer um
Neste caso: **5.5**

Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não



Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não

Grupo de Estudos


Atributo	Índice Gini
Lista de Exercícios	0.404
Grupo de Estudos	0.214
Horas de Estudo < 5.5	0.343

Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Este nodo é completamente puro:
transformar em nodo folha!

Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não




Árvores de Decisão

Indução

- Decidir qual atributo será o próximo nodo
 - Atributo que melhor prevê a aprovação/reprovação


Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	2	Não
Sim	Não	5	Não
Não	Sim	6	Sim
Não	Sim	12	Sim
Sim	Sim	14	Sim
Sim	Não	20	Não
Não	Não	30	Não



Árvores de Decisão

Predição

- Utilizar modelo induzido para dados não-vistos!




Árvores de Decisão

Predição

- Utilizar modelo induzido para dados não-vistos!

Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	15	???




Árvores de Decisão

Predição

- Utilizar modelo induzido para dados não-vistos!


Lista de Exercícios	Grupo de Estudos	Horas de Estudo	Aprovado
Sim	Sim	15	Sim



Árvores de Decisão

Indução


- Nossa árvore está completamente ajustada aos dados de treinamento (100% acurácia) - possível **overfitting**



Árvores de Decisão

Indução


- Nossa árvore está completamente ajustada aos dados de treinamento (100% acurácia) - possível **overfitting**
- Solução 1: mudar **critério de parada**



Árvores de Decisão

Indução


- Nossa árvore está completamente ajustada aos dados de treinamento (100% acurácia) - possível **overfitting**
- Solução 1: mudar **critério de parada**
- Solução 2: **poda** (pruning) - simplificação do modelo



Árvores de Decisão

Indução

- Nossa árvore está completamente ajustada aos dados de treinamento (100% acurácia) - possível **overfitting**
- Solução 1: mudar **critério de parada**
- Solução 2: **poda** (pruning) - simplificação do modelo



Poda de Árvores de Decisão

- No processo de construção, árvores de decisão podem conter ruídos

Poda de Árvores de Decisão

- No processo de construção, árvores de decisão podem conter ruídos
 - Árvores induzidas podem sofrer de **overfitting** e classificar novos exemplos de forma não confiável

Poda de Árvores de Decisão

- No processo de construção, árvores de decisão podem conter ruídos
 - Árvores induzidas podem sofrer de **overfitting** e classificar novos exemplos de forma não confiável
 - Árvore induza também tende a ser muito grande e complexa, o que dificulta sua compreensão

Poda de Árvores de Decisão

- No processo de construção, árvores de decisão podem conter ruídos
 - Árvores induzidas podem sofrer de **overfitting** e classificar novos exemplos de forma não confiável
 - Árvore induza também tende a ser muito grande e complexa, o que dificulta sua compreensão
- Podar a árvore pode minimizar estes problemas e reduzir o **erro de generalização**

Poda de Árvores de Decisão

- No processo de construção, árvores de decisão podem conter ruídos
 - Árvores induzidas podem sofrer de **overfitting** e classificar novos exemplos de forma não confiável
 - Árvore induza também tende a ser muito grande e complexa, o que dificulta sua compreensão
- Podar a árvore pode minimizar estes problemas e reduzir o **erro de generalização**
 - Existem duas estratégias principais para a poda:
 - Pré-poda
 - Pós-poda

Poda de Árvores de Decisão

Pré-poda

- Estratégia utilizada durante o processo de construção da árvore quando um critério é satisfeito

Poda de Árvores de Decisão

Pré-poda

- Estratégia utilizada durante o processo de construção da árvore quando um critério é satisfeito
 - Utilizada para prevenir a construção de ramos que não melhoram a capacidade preditiva da árvore

Poda de Árvores de Decisão

Pré-poda

- Estratégia utilizada durante o processo de construção da árvore quando um critério é satisfeito
 - Utilizada para prevenir a construção de ramos que não melhoram a capacidade preditiva da árvore
 - Interromper o crescimento da árvore segundo algum critério (valor de medida de impureza, número mínimo de instâncias atingido, etc)

Poda de Árvores de Decisão

Pré-poda

- Estratégia utilizada durante o processo de construção da árvore quando um critério é satisfeito
 - Utilizada para prevenir a construção de ramos que não melhoram a capacidade preditiva da árvore
 - Interromper o crescimento da árvore segundo algum critério (valor de medida de impureza, número mínimo de instâncias atingido, etc)
- Critérios de parada:
 - Todos os exemplos alcançando um nó pertencem à mesma classe
 - Todos os exemplos alcançando um nó tem o mesmo vetor de atributos
 - A árvore atingiu uma profundidade máxima pré-definida

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore
 - Crescer a árvore até a homogeneidade de classes

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore
 - Crescer a árvore até a homogeneidade de classes
 - Cortar os nós de maneira bottom-up

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore
 - Crescer a árvore até a homogeneidade de classes
 - Cortar os nós de maneira bottom-up
 - Se erro de generalização melhorar após o corte, trocar sub-árvore por nó folha

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore
 - Crescer a árvore até a homogeneidade de classes
 - Cortar os nós de maneira bottom-up
 - Se erro de generalização melhorar após o corte, trocar sub-árvore por nó folha
- **Pessimistic Error Pruning**
 - Utiliza taxas de erro para tomar decisões sobre poda de subárvores
 - Estima o erro a partir dos próprios dados de treinamento, erro de treinamento é tendencioso, e portanto não pode ser utilizado como medida confiável para avaliar se nós podem ser podados.
 - Solução: ajustar o erro de treinamento de forma a penalizar pela criação de novos nós

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore
 - Crescer a árvore até a homogeneidade de classes
 - Cortar os nós de maneira bottom-up
 - Se erro de generalização melhorar após o corte, trocar sub-árvore por nó folha
- **Cost-Complexity Pruning**
 - Considera o custo-complexidade de uma árvore como uma função do número de folhas (ou tamanho da árvore) e da taxa de erro da classificação
 - Inicia da base, avaliando para cada nó interno N o custo-complexidade de sua subárvore, e o custo-complexidade resultante da poda da subárvore
 - Avaliação é feita com um conjunto de poda (dados independentes do conjunto de treinamento)

Poda de Árvores de Decisão

Pós-poda

- Estratégia realizada após o término do processo de construção da árvore
 - Crescer a árvore até a homogeneidade de classes
 - Cortar os nós de maneira bottom-up
 - Se erro de generalização melhorar após o corte, trocar sub-árvore por nó folha
- **Error-Based Pruning**
 - Calculados para nós candidatos à poda:
 - Erro estático: número de classificações incorretas considerando que todos os exemplos que chegam ao nó serão classificados de acordo com sua classe majoritária
 - Erro backed-up: soma das classificações incorretas de todas subárvores deste nó

Navalha de Occam


- A explicação de qualquer fenômeno deve fazer o menor número possível de suposições, eliminando aquelas que não fazem diferença nas previsões observáveis da hipótese explicativa ou da teoria

Navalha de Occam

- A explicação de qualquer fenômeno deve fazer o menor número possível de suposições, eliminando aquelas que não fazem diferença nas previsões observáveis da hipótese explicativa ou da teoria
- Dado dois exemplos com erro de generalização similares, deve-se preferir o **modelo mais simples** em relação ao modelo mais complexo
 - Para modelos complexos, há uma maior chance que tenha sido ajustado acidentalmente pelos erros nos dados
 - Portanto, deve-se considerar a complexidade do modelo durante a avaliação e escolha do mesmo

Árvores de Regressão

- Nós folhas sumarizam o valor do atributo alvo através da **média** destes valores para os exemplos que caem na folha
- Principal mudança: medida de divisão de nós
- A escolha do melhor atributo na divisão de nós se dá a partir da máxima redução na variância associada aos dados, comparando a variância original (antes da divisão) e a variância após a divisão de nó (soma ponderada das variâncias de cada partição)



Vantagens e Desvantagens


- Vantagens:
 - Interpretabilidade (fácil de compreender)
 - Possível gerar regras com base nas árvores
 - Flexibilidade

Vantagens e Desvantagens

- Vantagens:
 - Interpretabilidade (fácil de compreender)
 - Possível gerar regras com base nas árvores
 - Flexibilidade
- Desvantagens
 - Podem tornar-se muito grandes
 - Sujeitas a **overfitting** (super ajuste aos dados)
 - Geram apenas hiperplanos paralelos aos eixos (não lidam bem com atributos correlacionados)
 - Instabilidade, pequenas variações no conjunto de treinamento podem produzir grandes variações na árvore final

Vantagens e Desvantagens

Exemplos do Problema de Hiperplanos Estritamente Paralelos:



Vantagens e Desvantagens

Árvores de Decisão **não possuem viés de restrição** (são capazes de representar qualquer função de classificação de dados)

- Qual o limite inferior de taxa de erro que árvores construídas a partir do critério de **homogeneidade** de classes são capazes de atingir nos dados de treinamento?

Vantagens e Desvantagens

Árvores de Decisão **não possuem viés de restrição** (são capazes de representar qualquer função de classificação de dados)

- Qual o limite inferior de taxa de erro que árvores construídas a partir do critério de **homogeneidade** de classes são capazes de atingir nos dados de treinamento?
 - **Resposta:** 0
- Logo, Árvores de Decisão estão mais sujeitas a **underfitting** ou **overfitting**?

Vantagens e Desvantagens

Árvores de Decisão **não possuem viés de restrição** (são capazes de representar qualquer função de classificação de dados)

- Qual o limite inferior de taxa de erro que árvores construídas a partir do critério de **homogeneidade** de classes são capazes de atingir nos dados de treinamento?
 - **Resposta:** 0
- Logo, Árvores de Decisão estão mais sujeitas a **underfitting** ou **overfitting**?
 - **Resposta:** overfitting

Vantagens e Desvantagens

Árvores de Decisão **não possuem viés de restrição** (são capazes de representar qualquer função de classificação de dados)

- Qual o limite inferior de taxa de erro que árvores construídas a partir do critério de **homogeneidade** de classes são capazes de atingir nos dados de treinamento?
 - **Resposta:** 0
- Logo, Árvores de Decisão estão mais sujeitas a **underfitting** ou **overfitting**?
 - **Resposta:** overfitting

Árvores de Decisão **possuem viés de busca** (preferência por modelos)

- Atributos que geram maior redução de impureza estão nos níveis superiores
- Este viés implica em uma tendência a priorizar árvores mais curtas

Leitura Recomendada

Livros:

- [Tan et al. 2006] Seção 4.3
- [Faceli et al. 2011] Capítulo 6