

Métricas de Avaliação de Modelos de Classificação

Ao avaliar um modelo de classificação em aprendizado de máquina, utilizamos diversas métricas que ajudam a entender o desempenho do modelo. Dentre as principais métricas estão a acurácia, a precisão, o recall e a matriz de confusão. Vamos entender cada uma delas.

1. Matriz de Confusão

A matriz de confusão é uma tabela que descreve o desempenho de um modelo de classificação comparando os valores reais com as previsões feitas pelo modelo. Para um problema binário, a matriz de confusão é representada da seguinte forma:

	Predito Positivo	Predito Negativo
Real Positivo	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real Negativo	Falso Positivo (FP)	Verdadeiro Negativo (VN)

- Verdadeiro Positivo (VP): Casos corretamente classificados como positivos.
- Falso Negativo (FN): Casos que são positivos, mas o modelo classificou como negativos.
- Falso Positivo (FP): Casos que são negativos, mas o modelo classificou como positivos.
- Verdadeiro Negativo (VN): Casos corretamente classificados como negativos.

2. Acurácia

A acurácia é a proporção de previsões corretas em relação ao total de previsões feitas. É uma boa medida quando as classes estão balanceadas.

Fórmula:

$$\text{Acurácia} = (VP + VN) / (VP + VN + FP + FN)$$

3. Precisão

A precisão (ou valor preditivo positivo) mede a proporção de previsões positivas que realmente são positivas. É uma métrica útil quando o custo de um falso positivo é alto.

Fórmula:

$$\text{Precisão} = VP / (VP + FP)$$

4. Recall (Sensibilidade ou Revocação)

O recall mede a capacidade do modelo de identificar corretamente as instâncias positivas, ou seja, quantos dos positivos reais foram corretamente previstos. É uma métrica importante quando o custo de um falso negativo é alto.

Fórmula:

$$\text{Recall} = VP / (VP + FN)$$

5. Considerações

- Se queremos evitar falsos positivos, damos mais importância à precisão.
- Se queremos evitar falsos negativos, focamos no recall.

- A acurácia pode ser enganosa se os dados estiverem desbalanceados.
 - A matriz de confusão ajuda a visualizar o desempenho do modelo de forma detalhada.
- Essas métricas são fundamentais para avaliar modelos de classificação em aprendizado de máquina e permitem ajustes para melhorar a performance dependendo do contexto da aplicação.