

Regressão Linear


Regressão Linear

Um exemplo prático:

- **Dataset:** preços de casas de Portland

	Size	Price (USD, thousands)
#1	2104	460
#2	1416	232
#3	1534	315
#4	852	178

...





Regressão Linear

Um exemplo prático:

- **Dataset:** preços de casas de Portland
- **Tarefa:** prever o preço de uma casa dado seu tamanho (Regressão)

	Size	Price (USD, thousands)
#1	2104	460
#2	1416	232
#3	1534	315
#4	852	178

...



Regressão Linear

Regressão Linear **Univariada:**


- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear

Regressão Linear **Univariada**:

- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$


Coeficiente linear Coeficiente angular

Vamos relembrar a influência destes dois parâmetros na equação da reta...

Regressão Linear


Regressão Linear **Univariada**:

- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\theta_0 = 1.5, \theta_1 = 0$$

$$\hat{f}(x) = 1.5 + 0x$$



Não importa o valor da casa, nossa saída é constante (sempre prevemos o mesmo valor)

Regressão Linear


Regressão Linear **Univariada**:

- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$


$$\theta_0 = 1.5, \theta_1 = 0$$

$$\hat{f}(x) = 1.5 + 0x$$



$$\theta_0 = 0, \theta_1 = 0.5$$

$$\hat{f}(x) = 0 + 0.5x$$






Se $\theta_0 = 0$, nossa reta passa pela origem. θ_1 regula a angulação da reta. Para este valor de θ_1 , é como se estivéssemos dizendo que o preço de uma casa é dado pela metade de seu tamanho

Regressão Linear

Regressão Linear **Univariada**:

- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$



Regressão Linear

Regressão Linear **Univariada**:

- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Em abordagens paramétricas de otimização, é comum chamar o parâmetro θ_0 de parâmetro livre ou de bias (viés). Isto dá liberdade para o modelo ajustar suas previsões de maneira independente aos dados

- Não confundir com viés indutivo, restrição, etc.

Regressão Linear

Regressão Linear **Univariada:**

- Somente um atributo. Função preditiva modela uma **relação linear**

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Podemos observar que todos os resultados geram **hiperplanos separadores**

- Modelos de Regressão Linear possuem **viés de restrição**


Regressão Linear

Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**

$$\hat{f}(x^i) - f(x^i)$$

Um jeito possível para medir este “encaixe” do modelo com os dados é calcular a **diferença** entre o resultado predito e o real



$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear


Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**

$$\hat{f}(x^i) - f(x^i)$$

Um jeito possível para medir este “encaixe” do modelo com os dados é calcular a **diferença** entre o resultado predito e o real

Porém, notem que o resultado deste cálculo possui sinal. Se superestimarmos o valor, teremos um valor **positivo**. Se subestimarmos o valor, teremos um valor **negativo**.



$$\hat{f}(x) = \theta_0 + \theta_1 x$$


Regressão Linear

Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**

$$\cancel{\hat{f}(x^i) - f(x^i)}$$
$$\left(\hat{f}(x^i) - f(x^i)\right)^2$$

Para evitarmos o “cancelamento” de erros, vamos **eleva**r ao quadrado a diferença entre o valor predito e o real



$$\hat{f}(x) = \theta_0 + \theta_1 x$$


Regressão Linear

Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**

$$\left(\hat{f}(x^i) - f(x^i) \right)^2$$
$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$

Agora podemos calcular a diferença entre uma predição individual do modelo e o resultado real. Como queremos que nosso modelo se aproxime de **todos** os resultados (em média), vamos calcular os resíduos de todas as instâncias e calcular o **valor médio**



$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear


Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**

$$\left(\hat{f}(x^i) - f(x^i)\right)^2$$
$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i)\right)^2$$

Assim, temos uma maneira de quantificar o “custo” de predição. Quanto maior for este valor, pior o modelo. Quando este valor atinge 0, o modelo não comete erros

Função de Custo: Erro Quadrático Médio




$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear

Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**



$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\left(\hat{f}(x^i) - f(x^i) \right)^2$$
$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$


$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$

Podemos dizer, então, que o que queremos é **minimizar** esta função de custo. O modelo possui controle de seus parâmetros, então queremos que ele encontre valores de maneira a minimizar o erro quadrático médio

Regressão Linear

Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**



$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\left(\hat{f}(x^i) - f(x^i) \right)^2$$
$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$


Esta divisão por 2 está ali por conveniência matemática (simplificar a derivada)

Podemos dizer, então, que o que queremos é **minimizar** esta função de custo. O modelo possui controle de seus parâmetros, então queremos que ele encontre valores de maneira a minimizar o erro quadrático médio

Regressão Linear

Regressão Linear **Univariada**:

- Dado um conjunto de dados, quais são os valores adequados de θ_0 e θ_1 ?
- **Ideia:** escolher valores para que a saída do modelo se pareça (ao máximo possível) com os dados de treinamento. **Como fazer isso?**



$$\left(\hat{f}(x^i) - f(x^i)\right)^2$$

$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i)\right)^2$$

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i)\right)^2$$

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

Nosso objetivo será descobrir valores de θ_0 e θ_1 de forma a minimizar o valor de J.

Isto é um problema de minimização que resolveremos através de um processo de otimização iterativo

Regressão Linear

Regressão Linear **Univariada:** Revisão

- **Modelo:** $\hat{f}(x) = \theta_0 + \theta_1 x$
- **Parâmetros:**
- **Função de Custo:**
- **Objetivo:**

Regressão Linear

Regressão Linear **Univariada:** Revisão

- **Modelo:** $\hat{f}(x) = \theta_0 + \theta_1 x$
- **Parâmetros:** θ_0, θ_1
- **Função de Custo:**
- **Objetivo:**

Regressão Linear

Regressão Linear **Univariada:** Revisão

- **Modelo:** $\hat{f}(x) = \theta_0 + \theta_1 x$
- **Parâmetros:** θ_0, θ_1
- **Função de Custo:** $J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$
- **Objetivo:**

Regressão Linear


Regressão Linear **Univariada:** Revisão

- **Modelo:** $\hat{f}(x) = \theta_0 + \theta_1 x$
- **Parâmetros:** θ_0, θ_1
- **Função de Custo:** $J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$
- **Objetivo:** $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Regressão Linear

Regressão Linear **Univariada**: Função de Custo

- **Loss Landscape**: informa os valores de custo no espaço contínuo.
- Objetivo: encontrar o **mínimo local** (ponto de menor custo)






Regressão Linear

Regressão Linear **Univariada**: Função de Custo

- Um modelo de regressão linear é uma instanciação de parâmetros θ_0 , θ_1

$$\theta_0 = 800, \theta_1 = -0.15$$






Regressão Linear

Regressão Linear **Univariada**: Função de Custo

- Um modelo de regressão linear é uma instanciação de parâmetros θ_0 , θ_1

$$\theta_0 = 800, \theta_1 = -0.15$$

$$\theta_0 = 500, \theta_1 = -0.025$$



Regressão Linear




Regressão Linear **Univariada**: Função de Custo

- Um modelo de regressão linear é uma instanciação de parâmetros θ_0 , θ_1

$$\theta_0 = 800, \theta_1 = -0.15$$

$$\theta_0 = 360, \theta_1 = 0$$

$$\theta_0 = 360, \theta_1 = 0$$



Regressão Linear

Regressão Linear **Univariada**: Função de Custo




- Um modelo de regressão linear é uma instanciação de parâmetros θ_0 , θ_1

$$\theta_0 = 800, \theta_1 = -0.15$$

$$\theta_0 = 360, \theta_1 = 0$$

$$\theta_0 = 500, \theta_1 = -0.025$$

$$\theta_0 = 100, \theta_1 = 0.13$$



Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$?

- Dada uma função de custo $\mathbf{J}(\theta_0, \theta_1)$
- Objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Dada uma função de custo $J(\theta_0, \theta_1)$
- Objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Algoritmo:

1. **Inicialize** com θ_0, θ_1 algum valor

Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Dada uma função de custo $\mathbf{J}(\theta_0, \theta_1)$
- Objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Algoritmo:

1. **Inicialize** com θ_0, θ_1 algum valor
2. Calcule o resultado da função de custo $\mathbf{J}(\theta_0, \theta_1)$

Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Dada uma função de custo $\mathbf{J}(\theta_0, \theta_1)$
- Objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Algoritmo:

1. **Inicialize** com θ_0, θ_1 algum valor
2. Calcule o resultado da função de custo $\mathbf{J}(\theta_0, \theta_1)$
3. Modifique θ_0, θ_1 **incrementalmente**, de forma a **reduzir** o valor de $\mathbf{J}(\theta_0, \theta_1)$

Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$? - **Gradiente Descendente**


- Dada uma função de custo $\mathbf{J}(\theta_0, \theta_1)$
- Objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Algoritmo:

1. **Inicialize** com θ_0, θ_1 algum valor
2. Calcule o resultado da função de custo $\mathbf{J}(\theta_0, \theta_1)$
3. Modifique θ_0, θ_1 **incrementalmente**, de forma a **reduzir** o valor de $\mathbf{J}(\theta_0, \theta_1)$
4. Repita do passo 2 até convergência ou critério de parada (ex.: num. iterações)

Regressão Linear


Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)



Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)


Escolhemos um valor inicial para os parâmetros



Regressão Linear


Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)

Calculamos o valor da função de custo e nos deslocamos na direção de maior declive




Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)




Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)




Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)




Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)




Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)



Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Intuição)



Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente**

- “Olhar para todas as direções e dar um passo na direção de maior declive”
 - **Derivada:** descobrir a direção de maior declive
 - α : Hiperparâmetro que regula o tamanho do passo

Repetir, até convergir: {

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

}

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente**

- “Olhar para todas as direções e dar um passo na direção de maior declive”
 - **Derivada:** descobrir a direção de maior declive
 - α : Hiperparâmetro que regula o tamanho do passo

Repetir, até convergir: {

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

}

Atenção: atualização simultânea!

$$\begin{aligned} \text{temp0} &:= \theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) \\ \text{temp1} &:= \theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) \end{aligned}$$


$$\theta_0 := \text{temp0}$$

$$\theta_1 := \text{temp1}$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ




$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ




$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ




$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

A derivada da função J com relação a θ fornece a inclinação da reta que é tangente à função no ponto em questão

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ



$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$


Notem que a inclinação desta
reta é positiva, então o
resultado deste cálculo de
derivada será positivo

$$\theta := \theta - \alpha \text{ (número positivo)}$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ



$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$


Como o valor de α é positivo e pequeno, atualização de θ será negativa e pequena

$$\theta := \theta - \alpha \text{ (número positivo)}$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ



$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$


Seguimos atualizando...

$$\theta := \theta - \alpha \text{ (número positivo)}$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Assuma a existência de uma função de custo com apenas um parâmetro θ



$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

Até que o valor da nossa derivada atinge 0 (mínimo global)


$$\theta := \theta - \alpha \text{ (número positivo)}$$

O gradiente aponta para o máximo da função, então damos um passo na direção contrária

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)


- Assuma a existência de uma função de custo com apenas um parâmetro θ



$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

Se tivéssemos escolhido um valor inicial de θ à esquerda, o valor da derivada será negativo, então daremos um passo no sentido oposto (sentido positivo)

$$\theta := \theta - \alpha \text{ (número positivo)}$$



$$\theta := \theta - \alpha \text{ (número negativo)}$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente** (Entendendo a derivada)

- Como saber que **tamanho de passo** devo dar?
- A escolha da taxa de aprendizado (α) é um dos hiperparâmetros mais importantes em algoritmos de aprendizado de máquina baseado em otimização
 - Valores muito baixos: convergência muito lenta
 - Valores muito altos: risco de divergência

Adequado (pequeno, mas não muito)



Ruim (muito grande)



Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Calculando as derivadas parciais para $\mathbf{J}(\theta_0, \theta_1)$ em Regressão Linear Univariada

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) =$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) =$$

Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Calculando as derivadas parciais para $\mathbf{J}(\theta_0, \theta_1)$ em Regressão Linear Univariada

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right) = \frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^i) - f(x^i) \right)$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) =$$

Regressão Linear

Como **minimizar** $\mathbf{J}(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Calculando as derivadas parciais para $\mathbf{J}(\theta_0, \theta_1)$ em Regressão Linear Univariada

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right)^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right) = \frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^i) - f(x^i) \right)$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^i) - f(x^i) \right) x^i = \frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^i) - f(x^i) \right) x^i$$

Regressão Linear

Como **minimizar** $J(\theta_0, \theta_1)$? - **Gradiente Descendente**

- Voltando ao algoritmo, agora com o cálculo das derivadas

Repetir, até convergir: {

$$\theta_0 := \theta_0 - \alpha \frac{1}{N} \sum_{i=1}^N ((\theta_0 + \theta_1 x^i) - f(x^i))$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{N} \sum_{i=1}^N ((\theta_0 + \theta_1 x^i) - f(x^i)) x^i$$


}

**Atualização
simultânea!**

Regressão Linear

Loss Landscape da função de custo de Regressão Linear


- Nossa função de custo J pode ter este formato, certo?



Regressão Linear

Loss Landscape da função de custo de Regressão Linear



- Nossa função de custo J pode ter este formato, certo? **ERRADO**



Regressão Linear




Loss Landscape da função de custo de Regressão Linear

- Nossa função de custo J pode ter este formato, certo? **ERRADO**
- O Erro Quadrático Médio define um problema de otimização **convexo**
 - Possui um único mínimo (que é o mínimo global)
 - “Bowl-shaped” - formato de tigela



Regressão Linear

Exemplo de Otimização:



Regressão Linear

Até agora, falamos sobre regressão linear **univariada** (somente um atributo preditivo)

	Size	Price (USD, thousands)
#1	2104	460
#2	1416	232
#3	1534	315
#4	852	178

...

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear

Até agora, falamos sobre regressão linear **univariada** (somente um atributo preditivo)

- E se tivermos **vários** atributos preditivos?

	Size	Price (USD, thousands)
#1	2104	460
#2	1416	232
#3	1534	315
#4	852	178

...

	Size	Num. Bedrooms	Num. Floors	Age	Price (USD, thousands)
#1	2104	5	1	45	460
#2	1416	3	2	40	232
#3	1534	3	4	30	315
#4	852	2	1	36	178

...

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear

Até agora, falamos sobre regressão linear **univariada** (somente um atributo preditivo)

- E se tivermos **vários** atributos preditivos?

	Size	Price (USD, thousands)
#1	2104	460
#2	1416	232
#3	1534	315
#4	852	178

...

	Size	Num. Bedrooms	Num. Floors	Age	Price (USD, thousands)
#1	2104	5	1	45	460
#2	1416	3	2	40	232
#3	1534	3	4	30	315
#4	852	2	1	36	178

...

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\hat{f}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$


Regressão Linear Multi-variada

Regressão Linear

Regressão Linear Multi-variada: **Notação**

- x_j^i : valor do j-ésimo atributo da i-ésimo instância

$$\hat{f}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$




Regressão Linear

Regressão Linear Multi-variada: **Notação**

- x_j^i : valor do j-ésimo atributo da i-ésimo instância

$$\hat{f}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$


$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$


Regressão Linear

Regressão Linear Multi-variada: **Notação**

- x_j^i : valor do j-ésimo atributo da i-ésima instância
- Vamos assumir a existência de um novo atributo: $x_0 = [1, 1, \dots, 1]^N$

$$\hat{f}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$


$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$


$$\hat{f}(\mathbf{x}) = \sum_{i=0}^m \theta_i x_i$$

Regressão Linear

Regressão Linear Multi-variada: **Notação**

- x_j^i : valor do j-ésimo atributo da i-ésima instância
- Vamos assumir a existência de um novo atributo: $x_0 = [1, 1, \dots, 1]^N$
- Considere o vetor de parâmetros $\Theta = [\theta_0, \theta_1, \dots, \theta_m]$

$$\hat{f}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$


$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$

$$\hat{f}(\mathbf{x}) = \sum_{i=0}^m \theta_i x_i$$

$$\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$$

Regressão Linear

Regressão Linear Multi-variada:

- **Modelo:** $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- **Parâmetros:**
- **Função de Custo:**
- **Objetivo:**

Regressão Linear

Regressão Linear Multi-variada:

- **Modelo:** $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- **Parâmetros:** Θ
- **Função de Custo:**
- **Objetivo:**

Regressão Linear

Regressão Linear Multi-variada:

- **Modelo:** $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- **Parâmetros:** Θ
- **Função de Custo:** $J(\Theta) = \frac{1}{2N} \sum_{i=1}^N (\Theta^T \mathbf{x}^i - f(\mathbf{x}^i))^2$
- **Objetivo:**

Regressão Linear

Regressão Linear Multi-variada:

- **Modelo:** $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- **Parâmetros:** Θ
- **Função de Custo:** $J(\Theta) = \frac{1}{2N} \sum_{i=1}^N (\Theta^T \mathbf{x}^i - f(\mathbf{x}^i))^2$
- **Objetivo:** $\min_{\Theta} J(\Theta)$

Regressão Linear

Regressão Linear Multi-variada: **Gradiente Descendente**

Repetir, até convergir: {

$$\theta_j := \theta_j - \alpha \frac{1}{N} \sum_{i=1}^N (\Theta^T \mathbf{x}^i - f(\mathbf{x}^i)) x_j^i$$

Para j = [0, 1, ..., m]


}

Regressão Linear

Regressão Linear: **Dicas**

- Normalizar os atributos para acelerar convergência
 - Padronização ou Estandarização (intervalos similares)
- Garanta que a implementação de gradiente descendente esteja funcionando
 - Plotar função de custo x iteração do gradiente descendente

Gradiente descendente necessariamente deve **reduzir** a função de custo a cada iteração!




Critério de parada:
parar de executar o algoritmo de a diferença da função de custo para duas iterações consecutivas for menor que um limiar ϵ (ex.: 10^{-3})

Regressão Linear

Regressão Linear: **Dicas**

- É importante analisar o comportamento da função de custo
 - Implementação pode estar errada ou α pode estar muito alto
 - Para valores suficientemente baixos de α , o gradiente descendente desce a cada iteração (mas cuidado, valores baixos levam à convergência muito lenta)



Regressão Linear

Regressão Linear: **Dicas**

- Heurística para escolha de α :
 - Começar com valores pequenos (ex.: 0.001)
 - Incrementar o valor por algum fator (ex.: 5, 10, etc.) para agilizar convergência (sempre conferindo se os valores estão decrescendo a cada iteração)
- Existem otimizadores mais complexos que o que vimos, com taxas de aprendizado adaptativas e outras melhorias. Explore a literatura!

Regressão Linear

Regressão Linear: **Solução Analítica**

- Vimos o algoritmo do gradiente descendente para minimizar a função de custo J , chegando nos valores de parâmetros do hiperplano de regressão que minimizam J
- **Equação Normal:** forma fechada para a descoberta dos parâmetros:
 - Ao setarmos as derivadas parciais da função de custo para 0, conseguimos descobrir os valores dos parâmetros de maneira analítica

$$\Theta = (X^T X)^{-1} X^T f(X)$$

Regressão Linear

Regressão Linear: **Solução Analítica**

- E se $(X^T X)$ for uma matriz não-inversível?
 - Utilizar pseudo-inversa (aproximações numéricas, diversos pacotes para isso)
 - Fazer seleção de atributos para eliminar atributos correlacionados (linearmente dependentes)
 - Pode ser pelo fato do problema ter mais atributos do que instâncias
 - Remover atributos
 - Usar regularização (veremos mais adiante)

Regressão Linear

Regressão Linear: **Solução Analítica VS Gradiente Descendente**

Gradiente Descendente:

- Precisa definir α
- Precisa de Muitas Iterações
- Funciona bem mesmo para problemas altamente dimensionais (muitos atributos)

Solução Analítica

- Não precisa definir α
- Não precisa iterar
- Lento se dimensionalidade do problema é muito alta (custo de inverter matriz)

Regressão Linear

Regressão Linear: **Dica Final**

- O gradiente descentente que vimos é o tradicional (Batch Gradient Descent)
 - Leva em conta todos os dados de treinamento para fazer uma atualização
 - Para problemas com muitos dados, isto é computacionalmente inviável
- Solução: **Gradiente Descendente Estocástico (SGD)**
 - Utiliza mini-batches (conjunto de amostras) para fazer atualizações
 - Aproxima o gradiente global
 - Mais robusto para funções não-convexas (aleatoriedade evita cair em mínimos locais e ajuda com outros problemas mais complexos)