

Regressão Logística

Regressão Logística

Apesar do nome **Regressão Logística** é um algoritmo de **classificação**!

- Regressão Linear: $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?

Regressão Logística

Apesar do nome **Regressão Logística** é um algoritmo de **classificação**!

- Regressão Linear: $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?

$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$


Regressão Logística

Apesar do nome **Regressão Logística** é um algoritmo de **classificação**!

- Regressão Linear: $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?
 - σ : função de ativação **Sigmóide**. Garante saída $0 \leq f(\mathbf{x}) \leq 1$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$



Regressão Logística

Apesar do nome **Regressão Logística** é um algoritmo de **classificação**!

- Regressão Linear: $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?
 - σ : função de ativação **Sigmóide**. Garante saída $0 \leq f(x) \leq 1$



$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$




$$\hat{f}(\mathbf{x}) = \frac{1}{1 + e^{-(\Theta^T \mathbf{x})}}$$

Regressão Logística

Regressão Logística:


- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo



Regressão Logística

Regressão Logística:


- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo
- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa



Regressão Logística

Regressão Logística:


- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo
- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa
- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?



Regressão Logística

Regressão Logística:

- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo
- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa
- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?
 - Se $\Theta^T \mathbf{x} \geq 0$, classe positiva




Regressão Logística

Regressão Logística:

- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo
- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa
- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?
 - Se $\Theta^T \mathbf{x} \geq 0$, classe positiva

$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$



Exemplo: problema com dois atributos

Regressão Logística

Regressão Logística:


- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo

- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa

- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?
 - Se $\Theta^T \mathbf{x} \geq 0$, classe positiva

$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$

Instâncias exatamente no hiperplano separador possuem valor $\sigma(\Theta^T \mathbf{x}) = 0.5$



Exemplo: problema com dois atributos


Regressão Logística

Regressão Logística:

- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo
- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa
- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?
 - Se $\Theta^T \mathbf{x} \geq 0$, classe positiva

$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$

Toda instância onde $\sigma(\Theta^T \mathbf{x}) \geq 0.5$ estará acima do hiperplano e será classificada como **positivo**



Exemplo: problema com dois atributos


Regressão Logística

Regressão Logística:

- Como temos uma saída entre $[0, 1]$, podemos ter uma **interpretação probabilística** da saída do modelo
- Se $\sigma(\Theta^T \mathbf{x}) \geq 0.5$: classe positiva
- Caso contrário, classe negativa
- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?
 - Se $\Theta^T \mathbf{x} \geq 0$, classe positiva

$$\hat{f}(\mathbf{x}) = \sigma(\Theta^T \mathbf{x})$$

Toda instância onde $\sigma(\Theta^T \mathbf{x}) < 0.5$ estará abaixo do hiperplano e será classificada como **negativo**



Exemplo: problema com dois atributos

Regressão Logística

Regressão Logística:

- Assim como na Regressão Linear, o problema de otimização novamente se resume a minimizar uma função de custo J
- Podemos usar a função de custo do erro quadrático médio?

$$J(\Theta) = \frac{1}{2N} \sum_{i=1}^N \left(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i) \right)^2$$

Regressão Logística

Regressão Logística:

- Assim como na Regressão Linear, o problema de otimização novamente se resume a minimizar uma função de custo J
- Podemos usar a função de custo do erro quadrático médio?
 - **Não**, pois quando aplicamos a função sigmoideal, $J(\Theta)$ vira uma função não-convexa (logo, possui vários ótimos locais)

$$J(\Theta) = \frac{1}{2N} \sum_{i=1}^N (\Theta^T \mathbf{x}^i - f(\mathbf{x}^i))^2$$

Regressão Logística

Regressão Logística: Função de Custo

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$


Regressão Logística

Regressão Logística: Função de Custo

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

Se $f(\mathbf{x}) = 1$




Regressão Logística

Regressão Logística: Função de Custo


$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

Se $f(\mathbf{x}) = 1$




Se $f(\mathbf{x}) = 0$



Regressão Logística

Regressão Logística: Função de Custo

- Não é conveniente, matematicamente falando, mantermos uma definição separada da função de custo. Vamos reescrever a função para incorporá-la

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i)) \quad \text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$


Regressão Logística

Regressão Logística: Função de Custo

- Não é conveniente, matematicamente falando, mantermos uma definição separada da função de custo. Vamos reescrever a função para incorporá-la

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i)) \quad \text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N -f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) - (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

Regressão Logística

Regressão Logística: Função de Custo

- Não é conveniente, matematicamente falando, mantermos uma definição separada da função de custo. Vamos reescrever a função para incorporá-la

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i)) \quad \text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N -f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) - (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) + (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

Regressão Logística

Regressão Logística: Função de Custo

- Não é conveniente, matematicamente falando, mantermos uma definição separada da função de custo. Vamos reescrever a função para incorporá-la

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\Theta^T \mathbf{x}^i - f(\mathbf{x}^i)) \quad \text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N -f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) - (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) + (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

Entropia Cruzada Binária

Regressão Logística

Regressão Logística: Entropia Cruzada Binária

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) + (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

- Função de custo convexa. Como minimizar?

Regressão Logística

Regressão Logística: Entropia Cruzada Binária

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^i) \log(\hat{f}(\mathbf{x}^i)) + (1 - f(\mathbf{x}^i)) \log(1 - \hat{f}(\mathbf{x}^i))$$

- Função de custo convexa. Como minimizar?
 - **Gradiente Descendente!**
 - Possui a mesma derivada que a função de custo da Regressão Linear!

Repetir, até convergir: {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\Theta) \longrightarrow \theta_j := \theta_j - \alpha \frac{1}{N} \sum_{i=0}^N \left(\hat{f}(\mathbf{x}^i) - f(\mathbf{x}^i) \right) x_j^i$$

Para $j = [0, 1, \dots, m]$

}

Regressão Logística


Regressão Logística: Otimização

- Existem algoritmos de otimização numérica mais efetivos que o gradiente descendente (porém, menos eficientes para grandes volumes de dados)
 - Gradiente Conjugado de Newton
 - BFGS (algoritmo de Broyden-Fletcher-Goldfarb-Shanno)
 - L-BFGS (Limited-memory BFGS)
- Todos estes algoritmos acima são complexos e tem uma implementação não-trivial
 - Utilizar bibliotecas (SciPy: `scipy.optimize`)

Regressão Logística

Regressão Logística: Problemas Multi-classe


- Até agora, vimos regressão logística para problemas de classificação binários



Regressão Logística

Regressão Logística: Problemas Multi-classe


- Até agora, vimos regressão logística para problemas de classificação binários
- Solução: **One-VS-All**
 - Treinar **C** classificadores, um para cada classe



Regressão Logística

Regressão Logística: Problemas Multi-classe


- Até agora, vimos regressão logística para problemas de classificação binários
- Solução: **One-VS-All**
 - Treinar **C** classificadores, um para cada classe



Regressão Logística

Regressão Logística: Problemas Multi-classe


- Até agora, vimos regressão logística para problemas de classificação binários
- Solução: **One-VS-All**
 - Treinar **C** classificadores, um para cada classe



Regressão Logística

Regressão Logística: Problemas Multi-classe


- Até agora, vimos regressão logística para problemas de classificação binários
- Solução: **One-VS-All**
 - Treinar **C** classificadores, um para cada classe



Regressão Logística

Regressão Logística: Problemas Multi-classe

- Até agora, vimos regressão logística para problemas de classificação binários
- Solução: **One-VS-All**
 - Treinar **C** classificadores, um para cada classe



$$\max_i \hat{f}(\mathbf{x})^i$$

Leitura Recomendada

Livros:

- [Abu-Mostafa et al 2012] Seções 3.2 e 3.3
- Tan et al. 2006] Apêndice D